L'IA: Démystification et Changement de Paradigmes

Celine Hudelot and Wassila Ouerdane

22/09/2026

MICS
CentraleSupélec
université PARIS-SACLAY

Avant-propos

Lectures conseillées - Références

- L'ouvrage de référence
  Artificial Intelligence: a modern approach.
  Russel and Norvig
- Un ensemble de codes associés
  https://github.com/aimacode

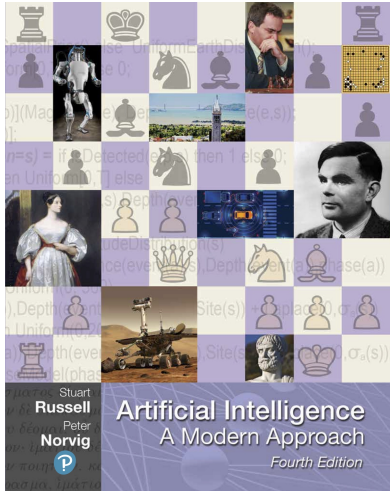

http://aima.cs.berkeley.edu/index.html

Lectures conseillées - Références

- Panorama de l'Intelligence Artificielle
  http://www.cepadues.com/collections/panorama-intelligence-artificielle-27.html

Lectures conseillées - Références

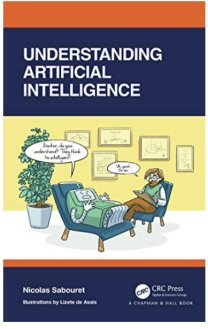

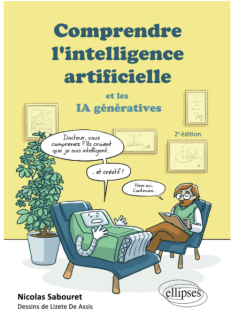

Lectures conseillées - Références

Quelques cours d'introduction aux fondements de l'IA:

- Stanford CS 221 Course: Artificial Intelligence : Principles and Techniques
  http://cs221.stanford.edu/
- Berkeley CS 188 : Intro to AI
  https://inst.eecs.berkeley.edu/~cs188/sp25/

Lectures conseillées - Références

Autres lectures intéressantes

- AI 100 : One Hundred Year Study on Artificial Intelligence. Deux rapports (2016 et 2021) https://ai100.stanford.edu/[1]
- Rapport de Cédric Villani : donner un sens à l'intelligence artificielle (IA) https://www.vie-publique.fr/rapport/37225-donner-un-sens-lintelligence-artificielle-pour-une-strategie-nation
- Rapport de la commission de l'IA : "IA : notre ambition pour la France". https://www.info.gouv.fr/upload/media/content/0001/09/4d3cc456dd2f5b9d79ee75feea63b47f10d75158.pdf

[1] voir aussi https://aaai-2022.virtualchair.net/plenary_12.html

Une communauté - Conferences

- IJCAI : International Joint Conference on Artificial Intelligence
  https://www.ijcai.org/
- ECAI : European Conference on Artificial Intelligence
  https://www.eurai.org/ecai
- AAAI : Association for the Advancement of Artificial Intelligence
  http://www.aaai.org/
- AFIA : Association Française pour l'Intelligence Artificielle
  http://afia.asso.fr/
- GDR RADIA : Groupement de Recherche *Raisonnement, Apprentissage, et Décision en Intelligence Artificielle*
  https://gdr-radia.cnrs.fr/

Organisation du cours

- **Cours 1: Démystification & Changements de Paradigmes** : Comprendre l'évolution historique et récente de l'IA, appréhender les ruptures majeures dans le domaine de l'informatique
- **TP Prise en Main & Ingénieur Augmenté** : Développer une maîtrise pratique des outils d'IA pour transformer son environnement de travail
- **Cours 2 Panorama des Modèles (Prédiction, Décision, Raisonnement)** : des algorithmes prédictifs classiques aux modèles génératifs et d'apprentissage par renforcement.

Introduction : de quoi parle-t-on ?

Définitions

Tentative de définition

L'intelligence artificielle est:

Une discipline de l'informatique dont le but est de construire des programmes ou des systèmes intelligents.

Tentative de définition

L'intelligence artificielle est:

Une discipline de l'informatique dont le but est de construire des programmes ou des systèmes intelligents.

- Qu'est ce qu'un **programme** ou un **système** ?
- Qu'est ce que l'**intelligence** ?

Tentative de définition

L'intelligence artificielle est:

Une discipline de l'informatique dont le but est de construire des programmes ou des systèmes intelligents.

- Qu'est ce qu'un **programme** ou un **système** ?
- Qu'est ce que l'**intelligence** ?

Plutôt que définir **ce qu'est l'IA**, on peut s'intéresser à **ce que l'IA peut faire pour nous !**

Tâches et capacités de l'IA

Un ensemble de tâches nécessitant de l'intelligence

Exemple : Jeux

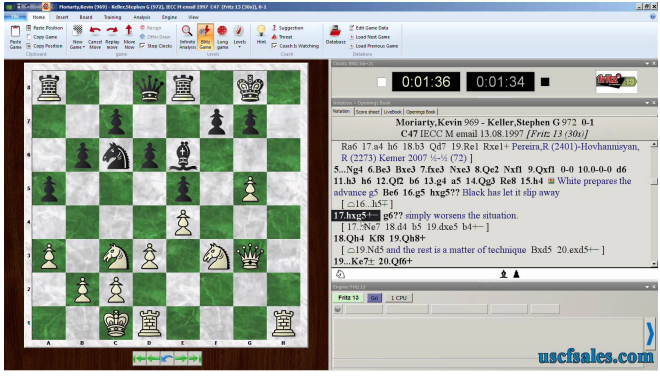

Prise de décision stratégique, action.

Un ensemble de tâches nécessitant de l'intelligence

Une des *réussites* les plus marquantes de l'IA : ***quand les machines battent les humains à leurs propres jeux***. Les jeux = la drosophile de l'IA.

1997: Deep Blue (chess)

2011: IBM Watson (Jeopardy!)

2016 : AlphaGo (Go)

Un ensemble de tâches nécessitant de l'intelligence

Les jeux = la drosophile de l'IA. Exemples plus récents. Agents autonomes - Apprentissage continu (benchmark sur le jeu Minecraft)

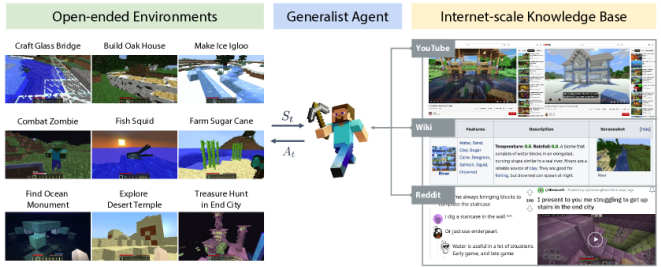

MineDojo[2], Voyager[3], agent autonome situé ou incarné (embodied agent) qui explore continuellement le monde, acquiert diverses compétences et fait de nouvelles découvertes sans intervention humaine.

[2] https://minedojo.org/
[3] https://github.com/MineDojo/Voyager

Un ensemble de tâches nécessitant de l'intelligence

Exemple : Robotique

Projet Cog MIT (http://www.ai.mit.edu/projects/humanoid-robotics-group/cog/)
"Humanoid intelligence requires humanoid interactions with the world"

Perception, compréhension, prise de décision, action, communication, apprentissage

Un ensemble de tâches nécessitant de l'intelligence

Exemple : Conduire un véhicule

Perception, compréhension, reconnaissance, prise de décision, action, apprentissage

Un ensemble de tâches nécessitant de l'intelligence

Exemple : Assistant virtuel - NLP - Traduction automatique - Complétion d'emails ... [4]

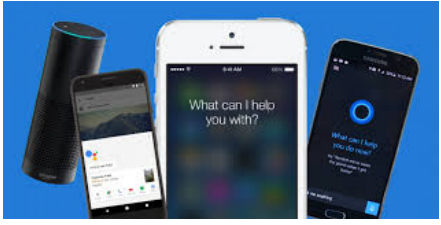

Autres exemples : Grammarly[5], DeepL[6]

Perception, compréhension, reconnaissance, prise de décision, action, apprentissage

[4] *e.g. Google Translate supporte 90 langues et 200 millions d'utilisateurs*

[5] https://www.grammarly.com/blog/how-grammarly-uses-ai/

[6] https://www.deepl.com/en/blog/20200206

Un ensemble de tâches nécessitant de l'intelligence

Reconnaissance visuelle[7] - Interprétation d'images

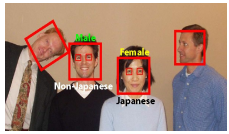

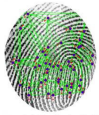

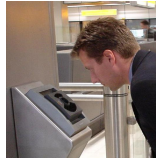

Prise de décision, perception, compréhension, reconnaissance, apprentissage

[7] Reconnaissance d'écritures manuscrites : *opérationnel dans le secteur postal depuis les années 2000 (Papier Y. LeCun, CNN en 1989).*

A retenir

Un agent intelligent doit donc :

- **Percevoir** et **Agir** dans son environnement
- **Interpréter, Comprendre, Reconnaître** : assimiler et traiter une information
- **Prendre une décision**

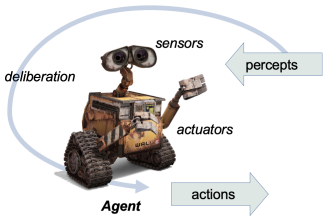

➡ **Procedural Loop**

Qu'est-ce que l'intelligence ?

Intelligence artificielle : définition d'un père fondateur

Marvin Minsky:
"Science qui consiste à faire faire aux machines ce que l'homme ferait moyennant une certaine intelligence"

Cédric Villani:
"L'intelligence artificielle, c'est toute technologie informatique qui permet de résoudre des problèmes complexes qu'on aurait cru réservés à l'intelligence humaine"

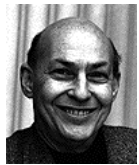

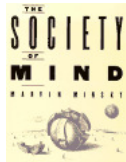

Définition relative à ce que savent faire les hommes

- Une certaine intelligence ?
- Quelle est la portée de faire faire ?

"Les choses les plus simples à faire par un humain (par exemple adapter son geste lorsqu'il saisit un objet) se sont avérées extrêmement complexes à reproduire sur une machine, tandis que des choses difficiles pour un humain (comme résoudre un problème d'échec) se sont avérées très simples "

Qu'est ce que l'*intelligence* ?

Plusieurs réponses

- Selon Turing
  C'est ce qui rend difficile la distinction entre une tâche réalisée par un humain ou par une machine

Qu'est ce que l'*intelligence* ?

Plusieurs réponses

- Selon Turing
  C'est ce qui rend difficile la distinction entre une tâche réalisée par un humain ou par une machine
- Selon Darwin
  C'est ce qui permet la survie de l'individu le plus apte

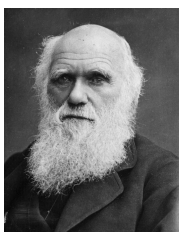

Qu'est ce que l'*intelligence* ?

Plusieurs réponses

- Selon Turing
  C'est ce qui rend difficile la distinction entre une tâche réalisée par un humain ou par une machine
- Selon Darwin
  C'est ce qui permet la survie de l'individu le plus apte
- Selon Edison
  C'est ce qui fait que cela fonctionne

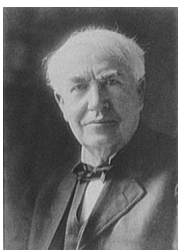

Qu'est ce que l'*intelligence* ?

Plusieurs réponses

- Selon Turing
  C'est ce qui rend difficile la distinction entre une tâche réalisée par un humain ou par une machine
- Selon Darwin
  C'est ce qui permet la survie de l'individu le plus apte
- Selon Edison
  C'est ce qui fait que cela fonctionne
- Selon Lorenz
  C'est collectif et cela emerge du comportement collectif

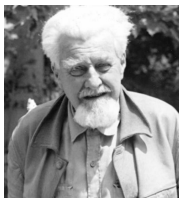

Intelligence artificielle: plusieurs courants

Plusieurs conceptions différentes de l'IA selon cette définition de l'intelligence :

- **Humain versus rationnel.**
  - Intelligence en terme de fidélité à la performance humaine.
  - Définition abstraite et formelle de l'intelligence : **la rationnalité** (i.e.faire les bons choix).
- **Raisonnement versus comportement.**
  - Intelligence comme une propriété d'un processus de pensée et de raisonnement interne.
  - Comportement intelligent en tant que caractérisation externe.

Intelligence artificielle: plusieurs courants

Penser comme des humains	Penser rationnellement
The exciting new effort to make computers think... machine with minds, in the full and litteral sense.(Haugeland,1985) *The automation of activities that we associate with human thinking, activities such as decision-making, problem sloving, learning.*(Bellman, 1978)	*The study of mental faculties through the use of computational models* (Charniak and Mc Dermott, 1985) *The study of the computation that make it possible to perceive, reason and act*(Winston, 1992)
Agir comme des humains	**Agir rationnellement**
The art of creating machines that perform functions that require intelligence when performed by humans (Kurzweil, 1990) *The study of how to make computers do things at which, at the moment, people are better*(Rich and Knight, 1991)	*Computational intelligence is the study of the design of intelligent agents*(Poole et al, 1998) *AI... is concerned with intelligence behavior in artifacts*(Nilsson, 1998)

Les disciplines qui ont contribué à l'IA

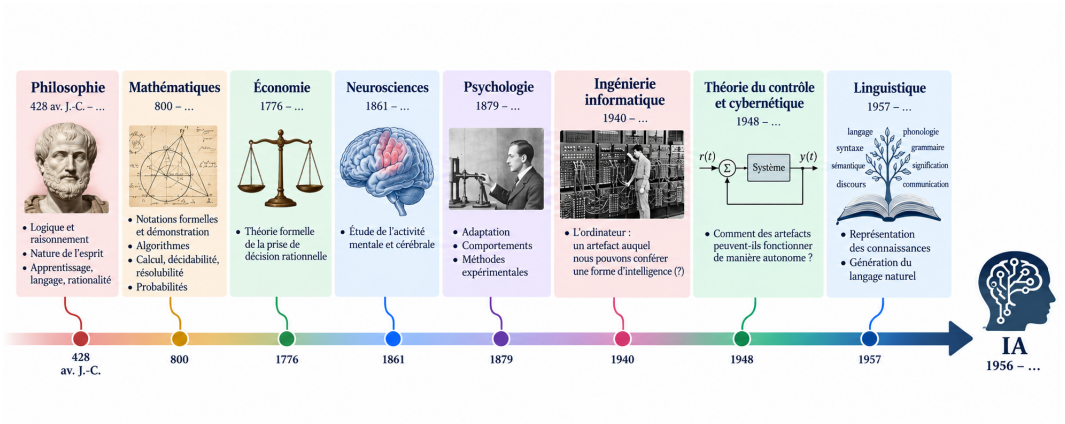

D'où vient l'IA ? Histoire et grands paradigmes

Qui repose sur plus d'une soixantaine d'années de recherche

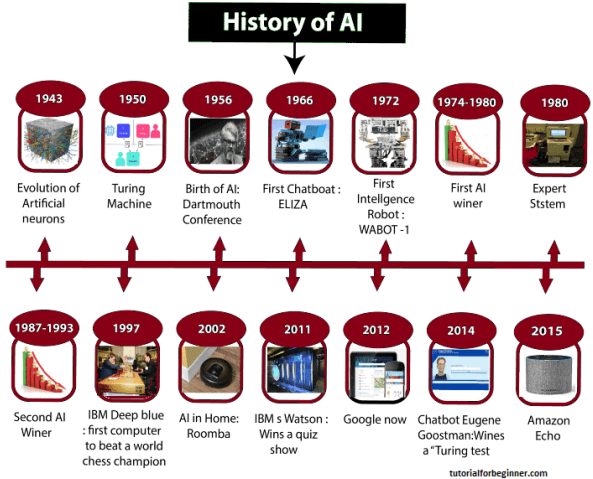

La gestation (1936-1955)

La gestation (1936-1955)

- Neurones artificiels [McCulloch and Pitts, 1943] : premier modèle formel du neurone.
- Turing: *Computing Machinery and Intelligence* : les fonctions calculables sont définies par une machine.
- Von Neumann et Oskar Morgenstern : fondements de la théorie des jeux, stratégies lors de la prise de décision

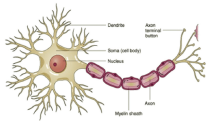

(a) Biological neuron

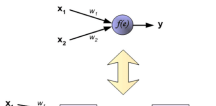

(b) Artificial neural network

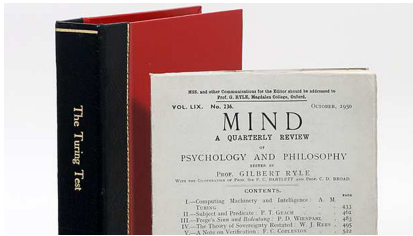

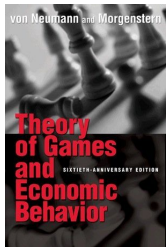

Les pères fondateurs : Claude Shannon et Alan Turing

Shannon (1916-2001)

- Théorie de l'information
- 1ère IA jouant aux échecs

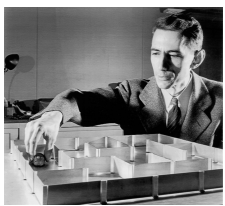

Turing (1912-1954)

- Machine de Turing
- Papier fondateur en 1950 (*"Est-ce qu'une machine pense ?"*)

La naissance et l'ère symbolique (1956 - 1980)

1956, la naissance : Conférence de Dartmouth

- Réunit 20 chercheurs en informatique.
- Le terme "Intelligence artificielle" est proposé [McCarthy].
- *"Tout aspect de l'apprentissage et de n'importe quelle caractéristique de l'intelligence peut être si précisément décrit qu'en principe, une machine devrait pouvoir être fabriquée pour simuler l'intelligence."*

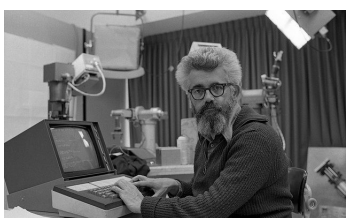

L'ère symbolique (1950–1980)

- **Principe :** L'intelligence est conçue comme la **manipulation de symboles** représentant explicitement des connaissances sur le monde (faits, règles, relations).

Idée centrale

Représenter les connaissances → Appliquer des règles → Résoudre un problème

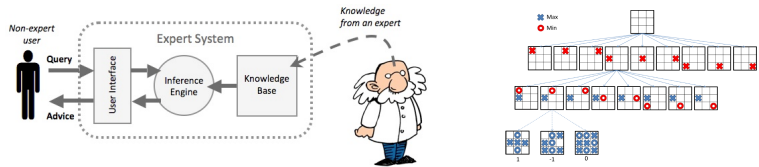

- **Concepts clés :** Logique, recherche dans des espaces d'états, représentation des connaissances et systèmes experts.
- **Exemples :** *Logic Theorist* (1956), ELIZA (1966), SHRDLU (1970), MYCIN (années 1970).

(Petite parenthèse) IA et raisonnement

Raisonnement par déduction

Conséquence à partir de faits : on part d'un cas (d'une fait) et de règles pour inférer un résultat

$$\frac{A \to B, A}{B}$$

- Fait : Socrate est humain. Règles : Tous les hommes sont mortels. Résultat : Donc Socrate est mortel

Raisonnement par induction

Règles à partir d'observations régulières. On part d'un cas et de résultats pour inférer une règle. (Valeurs de vérité incertaine).

$$\frac{B \text{ à chaque fois que A}}{A \to B}$$

- Cas : Socrate est humain. Résultat: Socrate est mortel. Règle : Donc, tous les humains sont mortels

Les pères fondateurs : l'IA symbolique

Newell & Simon

- **Résolution de problèmes**
- *Logic Theorist* (1956)
- Recherche dans des espaces d'états
- Modélisation des processus de décision
- Modèles symboliques de la cognition
- **Turing Award, 1975**

Minsky & McCarthy

- **Connaissances et raisonnement**
- Représentation des connaissances
- Systèmes de *frames*
- Raisonnement symbolique
- Fondements des systèmes experts
- **Turing Award, 1969**

Intelligence Artificielle Symbolique

Système expert MYCIN et autres

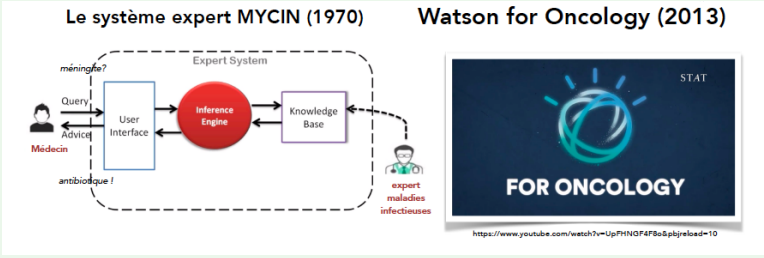

- Méthodes fortement développées dans les années 1980-2000
- (+) Principal avantage: explications claires de la prévision / de la décision
- (−) Difficulté du passage à l'échelle: nécessité de données d'entrée de relativement haut niveau.

Intelligence Artificielle Symbolique

Autre exemple : web sémantique

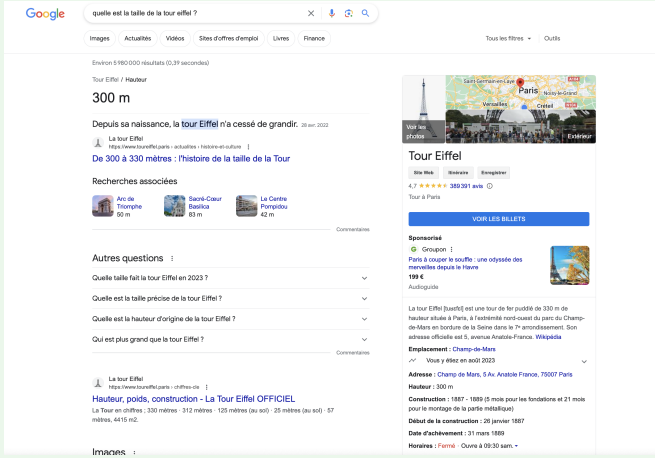

Représentation de la connaissance: exemple des knowledge graphs

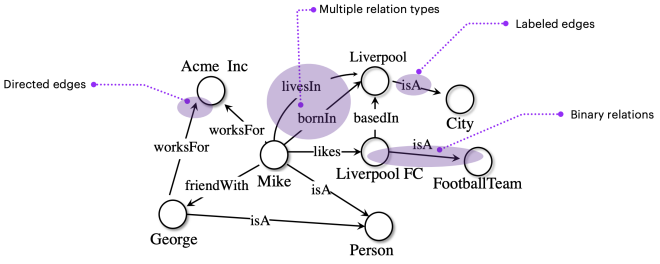

Intelligence Artificielle Symbolique

Représentation de la connaissance: ontologies

De très nombreuses ontologies dans le domaine biologique et médical, exemple : BioPortal

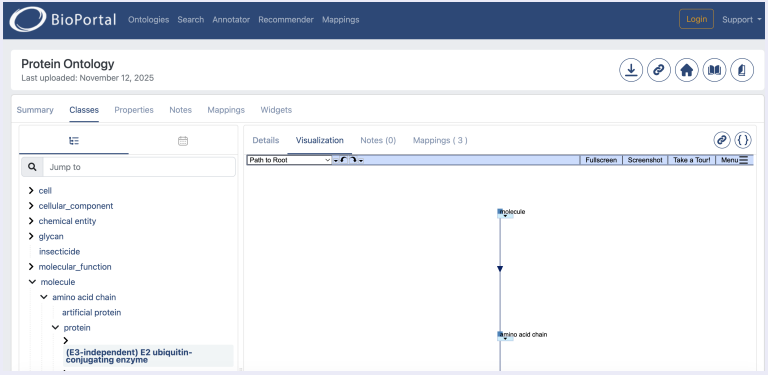

https://bioportal.bioontology.org/

Intelligence Artificielle Symbolique

Représentation de la connaissance: ontologies

De nombreux outils: exemple Pangyplot

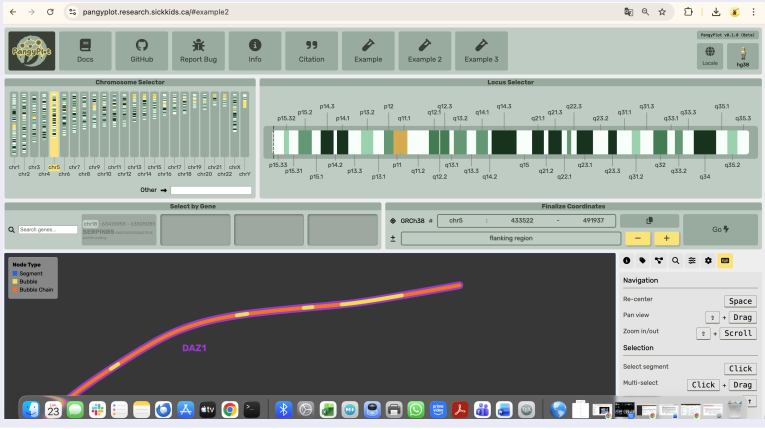

https://pangyplot.research.sickkids.ca

Symbolic Artificial Intelligence

Autres exemples : argumentation, décision collective

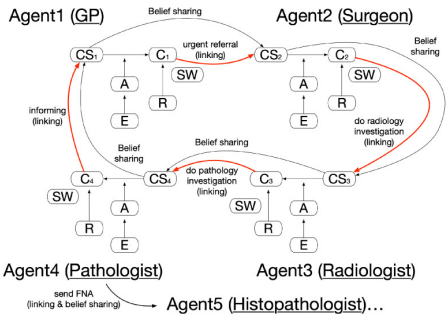

[Xiao et al, 23] Linked Argumentation Graphs for Multidisciplinary Decision Support
https://pmc.ncbi.nlm.nih.gov/articles/PMC9956294/

Symbolic Artificial Intelligence

Autres exemples : argumentation, décision collective

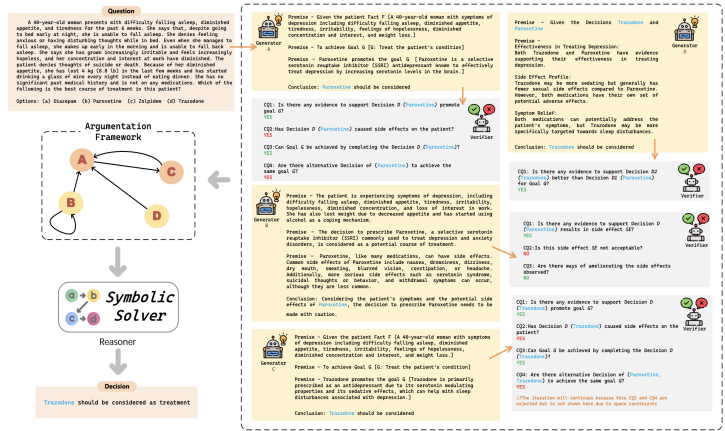

[Hong et al, 24] ArgMed-Agents: Explainable Clinical Decision Reasoning with LLM Discussion via Argumentation Schemes

https://arxiv.org/pdf/2403.06294

Symbolic Artificial Intelligence

Autres exemples : solvers, CSPs, ...

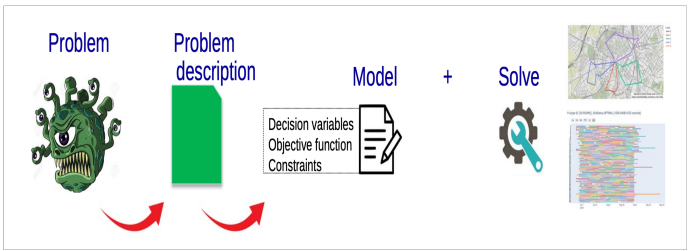

AI general problem solvers
CP, LP, SAT, ...

Intelligence Artificielle Symbolique– exemple en production

Source: https://list.cea.fr/fr/expressif-une-intelligence-artificielle-symbolique-contribue-au-developpement-des-artisans/ (2024)

L'IA symbolique

Principaux avantages

- Explications claires des prédictions / décisions : fonctionnement interne conceptuellement compréhensible.
- Nécessite seulement un faible nombre d'exemples en entrée.
- Utilise des langages déclaratifs puissants pour représenter les connaissances : forte expressivité.

L'IA symbolique

Principaux avantages

- Explications claires des prédictions / décisions : fonctionnement interne conceptuellement compréhensible.
- Nécessite seulement un faible nombre d'exemples en entrée.
- Utilise des langages déclaratifs puissants pour représenter les connaissances : forte expressivité.

Certaines limites

- Difficulté à passer à l'échelle : nécessite des données d'entrée relativement structurées.
- Demande un réglage manuel important.
- Absence de véritable apprentissage.
- Montre ses limites lorsqu'il s'agit de résoudre des problèmes du monde réel.

L'ère statistique et le Machine Learning (1980 - 2010)

L'essor du Machine Learning (1980–2010)

- **Principe :** Plutôt que de programmer explicitement les règles, on fournit des **données et des algorithmes** permettant à la machine d'apprendre des régularités et de reconnaître des motifs.
- **Concepts clés :** Apprentissage **supervisé** et **non supervisé**, SVM, arbres et forêts aléatoires, méthodes statistiques.
- **Rupture :** Le modèle n'est plus entièrement spécifié par l'humain : il **apprend ses règles de décision à partir des données**.
- **Exemples :** Filtres anti-spam, reconnaissance optique de caractères (OCR), reconnaissance de formes et systèmes de recommandation.

L'essor du Machine Learning (1980–2010)

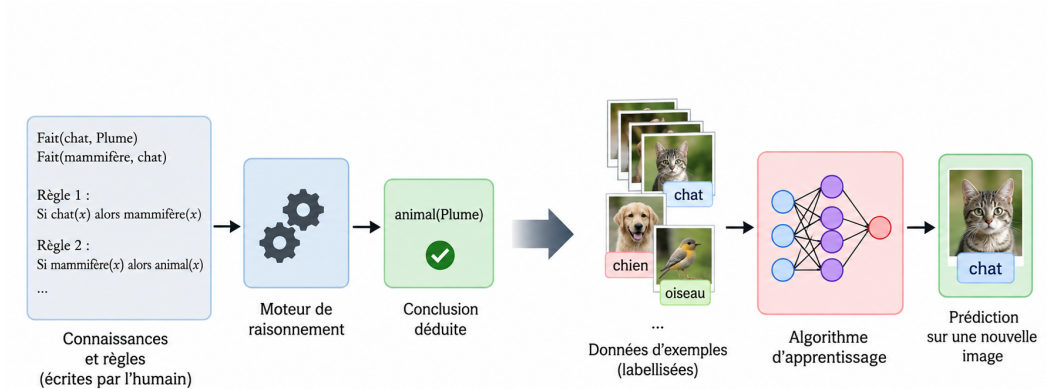

Apprentissage inductif

Le processus d'inférence se déroule en trois étapes :

1. Observation d'un phénomène.
2. Construction d'un modèle associé à ce phénomène.
3. Utilisation du modèle pour faire des prédictions liées à ce phénomène.

Apprentissage automatique

Automatisation de ce processus.

Hypothèse forte : il existe des relations entre les données, et les algorithmes nous permettront de les découvrir

Apprentissage automatique

- Point de départ :
  - Un ensemble d'**exemples** décrivant partiellement le comportement attendu du système : les données.
  - Un programme simple dont les paramètres sont inconnus : choix du type de modèle, l'espace des hypothèses.
- L'algorithme d'apprentissage apprend les paramètres du programme à partir des exemples afin de reproduire au mieux le comportement du système.
- La complexité ne réside pas dans la conception du programme lui-même.
- Point clé : la généralisation, c'est-à-dire la capacité du programme à fonctionner sur de nouveaux exemples.

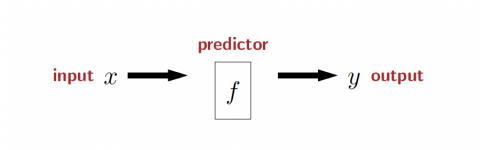

Figure: Source : cours cs221 Stanford - Liang

Les différents types d'apprentissage

Modèle par apprentissage

Différents cadre selon le type d'annotations des données.

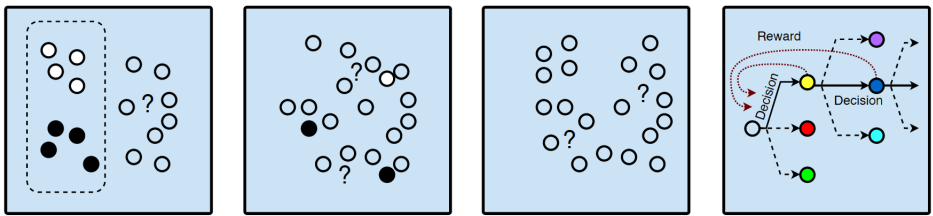

Figure: Source : V. Guigue

Modèle par apprentissage

Différents cadre selon le type de prédictions.

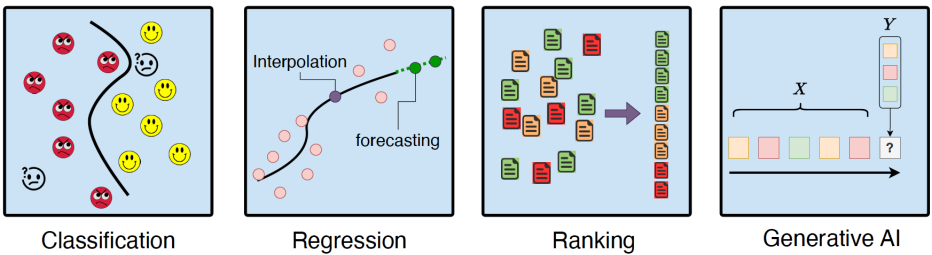

Figure: Source : V. Guigue

Apprentissage supervisé

Qu'est-ce que l'apprentissage supervisé ? (plus formellement)

On considère un espace d'entrée $\mathcal{X} \subseteq \mathbb{R}^d$ et un espace de sortie $\mathcal{Y} \subset \mathbb{R}$.

- Hypothèse fondamentale : Les paires d'exemples $(\mathbf{x}, y) \in \mathcal{X} \times \mathcal{Y}$ sont *identiquement et indépendamment distribuées* suivant une distribution de probabilité jointe fixe mais inconnue $\mathbb{P}(X, Y)$.
  - **i.e. Il existe une relation entre les entrées et les sorties.**
- Echantillons : On observe une séquence de m paires (x_i, y_i) générées suivant $\mathbb{P}$: $\mathcal{D} = (\mathbf{x_i}, y_i)_{i=1}^m \in (\mathcal{X} \times \mathcal{Y})$.
  - $\mathcal{D}$ **est l'ensemble d'apprentissage**
- But : Construire une fonction $f : \mathcal{X} \to \mathcal{Y}$ qui prédit la sortie y d'une nouvelle observation $\mathbf{x}$ avec une probabilité d'erreur minimale.

Théorie de l'apprentissage [Vapnik88]

Borner la probabilité d'erreur $R(f)$

$$R(f) \leq \text{erreur empirique de f} + \text{ Complexité de la classe de fonctions} + \text{ terme résiduel}$$

Remarques

1. La seule observation dont on dispose est l'ensemble des couples (x, y) : $\mathbb{P}$ est inconnue.
2. Cet ensemble $\mathcal{D} = ((x_1, y_1), (x_2, y_2), ..., (x_n, y_n))$ est l'ensemble d'apprentissage.
3. $x \in \mathcal{X}$. En général $\mathcal{X} \subseteq \mathbb{R}^d$.
   - x peut être une image, du texte, une table de transactions, des séries temporelles...
   - Une étape importante est l'étape de description des données d'entrées pour les transformer en un vecteur de caractéristiques $\Phi(x)$.
   - Cette étape peut être apprise (apprentissage profond, apprentissage de représentations) ou construite à la main (feature-engineering).
4. $y \in \mathcal{Y}$, selon le type de $\mathcal{Y}$, différents problèmes d'apprentissage.

Apprentissage supervisé : régression

On parle de regression si y est à valeurs réelles, i.e. $\mathcal{Y} = \mathbb{R}^m$.

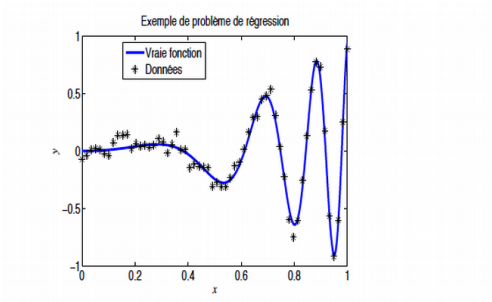

Source : G.Gasso

On ne dispose que des points (x_i, y_i) en noir et il faut estimer une fonction $f(x)$ qui donne une bonne estimation de la vraie fonction en bleu.

Apprentissage supervisé : régression

$x \longrightarrow \boxed{f} \longrightarrow y \in \mathbb{R}$ **response**

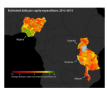

Poverty mapping: satellite image → asset wealth index

Housing: information about house → price

Arrival times: destination, weather, time → time of arrival

Figure: Source : CS221 Stanford

Apprentissage supervisé : classification binaire

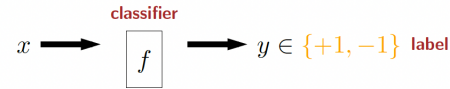

Fraud detection: credit card transaction → fraud or no fraud

Toxic comments: online comment → toxic or not toxic

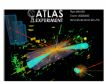

Higgs boson: measurements of event → decay event or background

Figure: Source : CS221 Stanford

Objectifs de l'apprentissage (supervisé)

On cherche à construire une fonction $f(x)$ à partir des n données d'apprentissage

$$\begin{array}{rll} f: & \mathcal{X} \rightarrow & \mathcal{Y} \\ & x \rightarrow & \hat{y} = f(x) \end{array}$$

Propriétés de $f(x)$

- $\forall (x_i, y_i) \in \mathcal{D}$, on veut que $f(x_i)$ prédise la bonne valeur de y_i ($\hat{y_i} = y_i$).
- f doit pouvoir prédire les bonnes sorties pour des exemples futurs x_j (généralisation).
- f appartient à un espace $\mathcal{H}$ appelé espace d'hypothèses.

Qualités attendues d'une technique d'apprentissage

- **Précision** : le taux d'erreur doit être le plus bas possible.
- **Robustesse** : le modèle doit dépendre aussi peu que possible de l'échantillon d'apprentissage et se généraliser à d'autres échantillons.
- **Concision, parcimonie** : les règles du modèles doivent être aussi simples et aussi peu nombreuses que possible.
- **Diversité des types de données utilisées** : données qualitatives, discrètes, continues et manquantes.
- **Rapidité de calcul du modèle** : apprentissage rapide pour affinement du modèle.
- **Paramètrage** : pouvoir pondérer les erreurs.

Comment mesurer la qualité d'une fonction apprise ?

Mesure de la qualité d'une fonction apprise

Fonction de coût (**loss fonction**)

Une fonction de coût permet d'évaluer la pertinence de la prédiction et de pénaliser les erreurs, i.e. lorsque la prédiction $\hat{y} = f(x)$ est différente de y.

$$L : \mathcal{Y} \times \mathcal{Y} \to \mathbb{R}^+ \text{ telle que } L(y, y') > 0 \text{ pour } y \neq y'$$

Le coût d'une bonne prédiction ($y = f(x)$) est plus faible que le coût d'une erreur ($y \neq f(x)$).

Exemples

- Exemple de fonction coût pour la classification binaire :
  Coût 0-1 $L(y_i, f(x_i)) = 0$ si $y_i = f(x_i)$, 1 sinon.
  Mesure le nombre de points mal classés.
- Exemple de fonction coût pour la regression :
  Coût quadratique $L(y_i, f(x_i)) = (y_i - f(x_i))^2$

Mesure de la qualité d'une fonction apprise

Notion de risque : On s'intéresse au comportement moyen de la fonction de perte (ou de coût).

Notion de risque

1. Risque, risque fonctionnel, erreur de généralisation : espérance de $L(y, f(x))$ par rapport à (x, y).

$$R(f) = E_{P(x,y)} L(y, f(x))$$

Représente en moyenne le coût pour toutes les données possibles : risque moyen ou erreur de généralisation
Il n'est pas possible de le calculer.

2. Risque empirique:

$$R_{emp}(f, \mathcal{D}) = \frac{1}{n} \sum_{i=1}^{n} L(y_i, f(x_i))$$

Représente en moyenne le coût pour toutes les données de l'ensemble d'apprentissage
Il est possible de le calculer.

Comment apprendre la fonction f ?

On cherche à construire une fonction $f_u(x)$ à partir de n données, u est l'ensemble des paramètres. $f_u(x)$ appartient à une classe d'hypothèses $\mathcal{H}$. $f_u(x)$ doit fournir de bonnes approximations non seulement sur ces n données, mais aussi sur les données futures.

- On aimerait minimiser le risque fonctionnel mais ce n'est pas possible.
- On va donc apprendre f_u en minimisant le risque empirique (Empirical Risk Minimization)

Apprentissage : un problème d'optimisation

On cherche une fonction $f_u \in \mathcal{H}$ parmi la classe qui minimise le risque empirique.

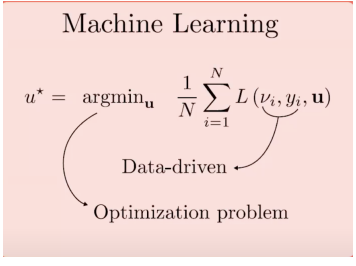

Les pères fondateurs : Judea Pearl et le raisonnement probabiliste

Judea Pearl (1936-)

- Traitement de l'incertitude
- Raisonnement probabiliste - Raisonnement causal
- Turing Award 2011

Les pères fondateurs : Vladimir Naoumovitch Vapnik et Alexey Chervonenkis

Alexey Chervonenkis (1938-2014) et Vladimir Vapnik (1936-)

- SVMs : séparateurs à vaste marge
- Théorie de l'apprentissage statistique
- Médaille John von Neumann en 2017

L'ère du Deep Learning et de la perception (2010 - 2020)

2012 : la révolution du deep learning

Challenge de reconnaissance visuelle (1000 classes)

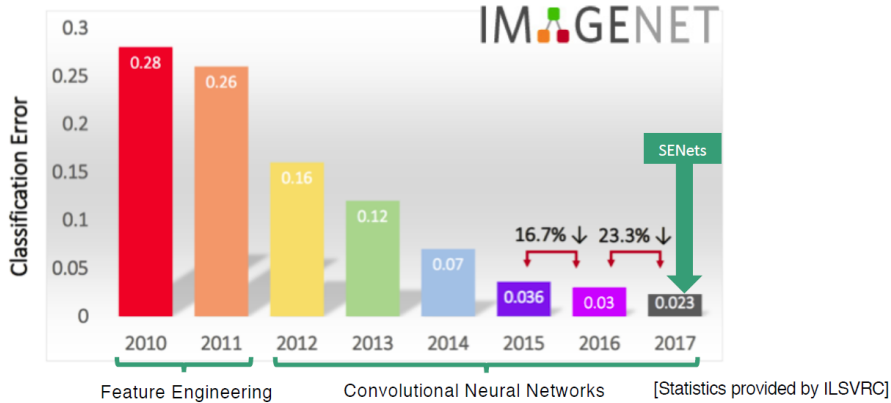

L'ère du Deep Learning et de la perception (2010–2020)

- **Principe :** Explosion de la puissance de calcul (GPU), des volumes de données et des technologies associées. Avancée des connaissances en optimisation. Les réseaux de neurones profonds deviennent performants à grande échelle.
- **Rupture :** Les représentations sont désormais **apprises automatiquement** à partir des données, réduisant fortement le recours à la conception manuelle des caractéristiques (*feature engineering*).
- **Succès :** Percées majeures en **vision par ordinateur** et en **reconnaissance vocale**, puis victoire d'**AlphaGo** contre Lee Sedol en 2016, illustrant les capacités du deep learning dans des tâches complexes.

L'ère du Deep Learning et de la perception (2010–2020)

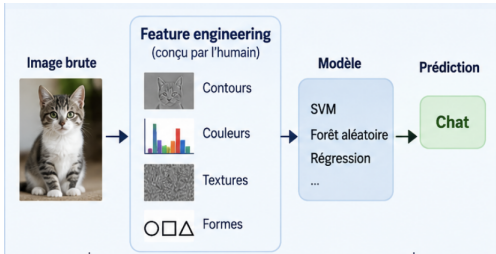

Caractéristiques

- Les caractéristiques sont conçues manuellement par un expert.
- Le modèle apprend à partir de ces caractéristiques.
- Nécessite une bonne connaissance du domaine.

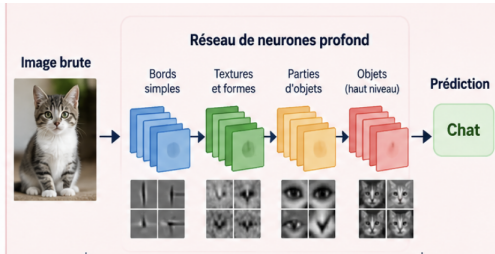

Caractéristiques

- Les représentations sont apprises automatiquement par le modèle.
- Le modèle extrait progressivement des motifs de plus en plus abstraits.
- Peu ou pas de feature engineering manuel.
- Très efficace avec de grandes quantités de données.

Réseau de Neurones Profonds

$\Longrightarrow Y = \psi(X)$, avec $\psi(X) = h_M \circ g_M \circ \ldots \circ h_1 \circ g_1(X)$ où h_i des transformations non-linéaires et g_i des transformations affines.

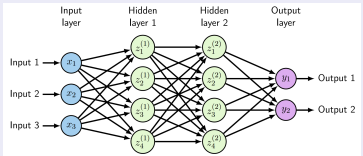

Réseau de Neurones Profonds

$\Longrightarrow$ $Y = \psi(X)$, avec $\psi(X) = h_M \circ g_M \circ \ldots \circ h_1 \circ g_1(X)$ où h_i des transformations non-linéaires et g_i des transformations affines.

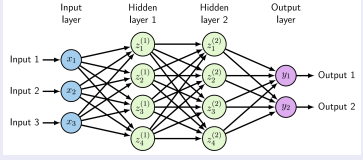

Apprentissage de représentations

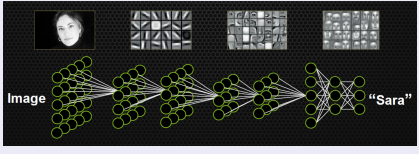

$\Longrightarrow$ Les couches profondes capturent des caractères complexes dans l'image permettant d'extraire l'information la plus pertinente pour la tâche de prédiction [Lee et al., 2009]

Les pères fondateurs : apprentissage et réseaux de neurones

Bengio (1964-), Hinton (1947-), Le Cun (1960-)

- Apprentissage profond
- Turing Award 2019

L'intelligence artificielle fondée sur les données

Principaux avantages

- Très performante sur de nombreuses tâches [a]
- Avantages de l'apprentissage inductif.
- Capacités de généralisation.

[a] Statistiquement impressionnante, mais individuellement peu fiable.

L'intelligence artificielle fondée sur les données

Principaux avantages

- Très performante sur de nombreuses tâches [a]
- Avantages de l'apprentissage inductif.
- Capacités de généralisation.

[a] Statistiquement impressionnante, mais individuellement peu fiable.

Certaines limites

- Manque de raisonnement de haut niveau dans le deep learning [Bottou, 2011] [a]
- Limites en matière de **généralisation compositionnelle** [b] : capacité de la cognition humaine à résoudre correctement tout problème composé de parties familières [c]
- Forte dépendance aux données.
- Fonctionnement opaque, manque de compréhensibilité.
- Peut être facilement trompée et attaquée.

[a] Bottou, Leon. (2011). From Machine Learning to Machine Reasoning. Computing Research Repository - CORR. 94. 10.1007/s10994-013-5335-x.
[b] https://compositionalintelligence.github.io/

Petite étude de cas?

Petite étude de cas?

Comment programmer une IA jouant aux échecs ? $\Rightarrow$ Besoin d'avoir une connaissance des règles du jeu

Petite étude de cas?

Comment programmer une IA jouant aux échecs ? $\Rightarrow$ Besoin d'avoir une connaissance des règles du jeu

Approche symbolique

- Modélisation explicite des règles de jeu : plateau, ensemble des coups possibles, algorithme de recherche de solutions gagnantes.
- **Faiblesses** : pour certains jeux, cette modélisation explicite est difficile.
- **Raisonnement déductif** : Utiliser des théories générales (connaissances) sur des cas particuliers pour déduire de nouveaux faits

Petite étude de cas?

Comment programmer une IA jouant aux échecs ? $\Rightarrow$ Besoin d'avoir une connaissance des règles du jeu

Approche symbolique

- Modélisation explicite des règles de jeu : plateau, ensemble des coups possibles, algorithme de recherche de solutions gagnantes.
- **Faiblesses** : pour certains jeux, cette modélisation explicite est difficile.
- **Raisonnement déductif** : Utiliser des théories générales (connaissances) sur des cas particuliers pour déduire de nouveaux faits

Approche orientée données

- Collecter des parties de jeu en quantité et apprendre les règles à partir de simples observations de parties.
- **Faiblesses** : le joueur peut jouer un coup illégal ou peut ne jamais jouer un coup légal.
- **Raisonnement inductif** : construction de théories générales à partir d'observations.

L'ère des Modèles de Fondation et de l'IA Générative (2020 - 2023)

Modèles de fondation et IA générative

- **Principe :** L'architecture **Transformer (2017)** permet un pré-entraînement à grande échelle. Combinée à l'augmentation massive des données, du calcul et de la taille des modèles, elle conduit aux **modèles de fondation**, dont les LLMs capables de générer du contenu.

- **Rupture :** Passage de modèles spécialisés à des modèles généralistes capables de générer et transformer du contenu à partir d'instructions en langage naturel.

- **Exemples :** GPT-3/4, Gemini, Midjourney, Stable Diffusion.

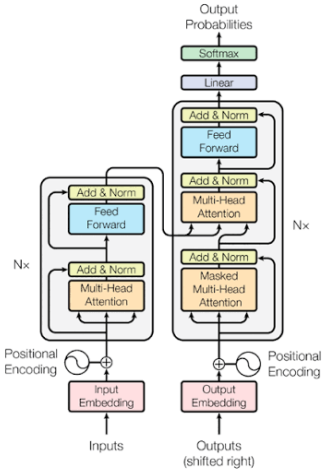

L'IA Générative!

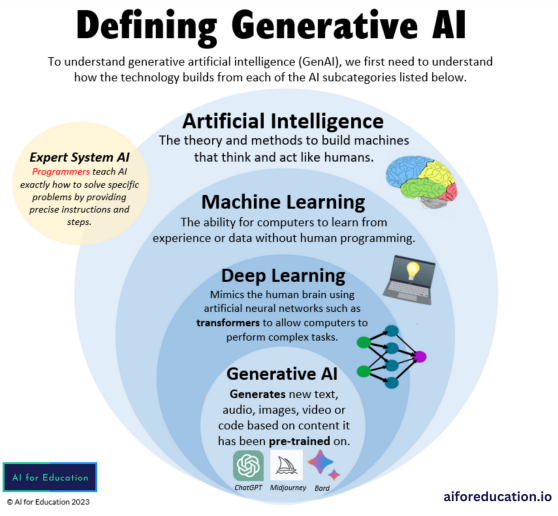

IA Générative : LLMs

Un LLM est un réseau neuronal conçu pour traiter et générer du texte humain.

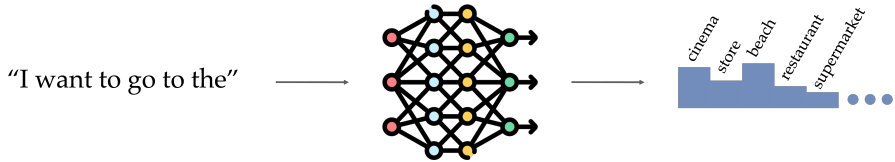

- Le modèle est entraîné avec une tâche de modélisation causale du langage (CLM) : prédire le token suivant étant donné tous les tokens précédents. (Pour les modèles bidirectionnels comme BERT : Masked Language Modelling).
- Cet apprentissage se fait de manière auto-supervisé (self-supervised learning) sur un très gros corpus (e.g. le WEB)
- Cette phase permet au modèle d'acquérir beaucoup de *connaissances* et de capacités.
- A l'inférence (utilisation du modèle), le LLM prédit, étant donnée une entrée appelée prompt, une distribution de probabilité pour les mots suivants étant donné un vocabulaire de mots ou tokens.

Slide credit : P. Colombo

IA Générative : LLMs à l'inférence

Comment un LLM génère du texte ? Il suit une approche progressive pour générer du texte, en commençant par un préfixe, puis en générant un mot à la fois.

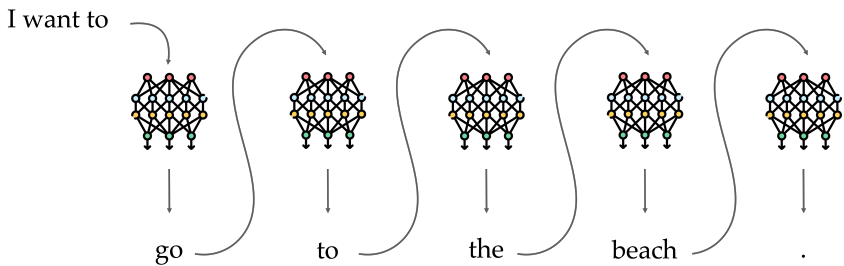

Slide credit : P. Colombo

IA Générative : LLMs

À l'ère moderne du NLP, deux types principaux de modèles dominent : les modèles génératifs à encodeur et à décodeur uniquement.

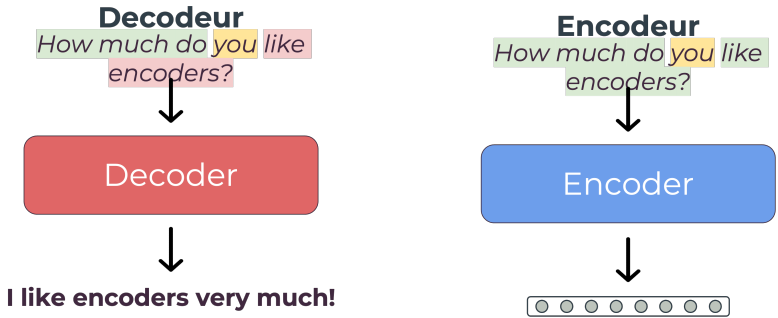

IA Générative : LLMs

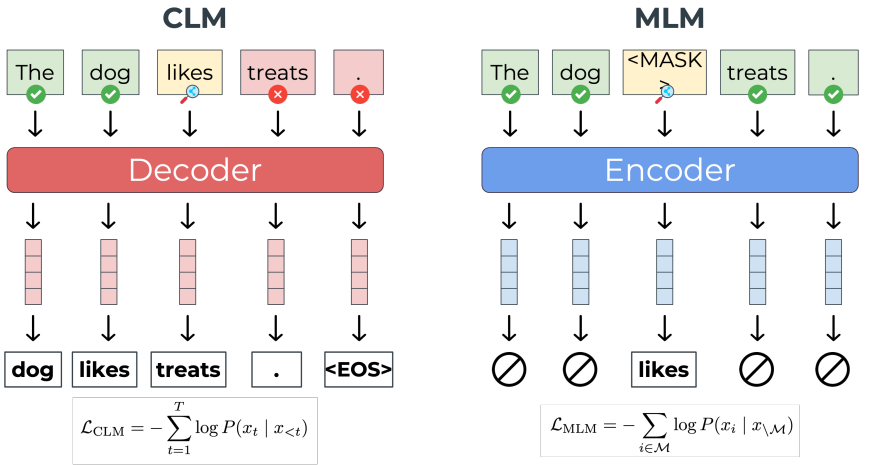

IA Générative : LLMs

Comment tirer parti des LLM pour n'importe quelle tâche ? **Prompting**

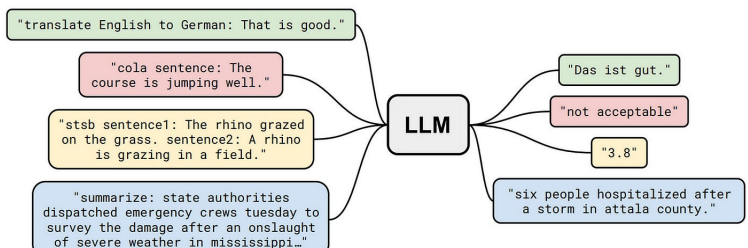

L'ère du prompt-engineering

- A prompt is composed with the following components:
  - Instructions
  - Context
  - Input data
  - Output indicator

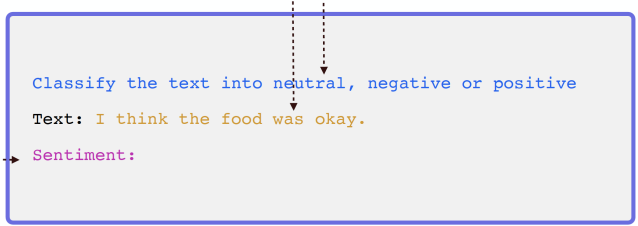

Question Answering

```
Answer the question based on the context below. Keep the
answer short and concise. Respond "Unsure about answer"
if not sure about the answer.

Context: Teplizumab traces its roots to a New Jersey drug
company called Ortho Pharmaceutical. There, scientists
generated an early version of the antibody, dubbed OKT3.
Originally sourced from mice, the molecule was able to
bind to the surface of T cells and limit their cell-
killing potential. In 1986, it was approved to help
prevent organ rejection after kidney transplants, making
it the first therapeutic antibody allowed for human use.

Question: What was OKT3 originally sourced from?

Answer: Mice.
```

Text Classification

```
Classify the text into neutral, negative or positive.

Text: I think the food was okay.

Sentiment: Neutral
```

Code Generation

```
"""
Table departments, columns = [DepartmentId,
DepartmentName]
Table students, columns = [DepartmentId, StudentId,
StudentName]
Create a MySQL query for all students in the Computer
Science Department
"""

SELECT StudentId, StudentName
FROM students
WHERE DepartmentId IN (SELECT DepartmentId FROM
departments WHERE DepartmentName = 'Computer Science');
```

Reasoning

```
The odd numbers in this group add up to an even number: 15,
32, 5, 13, 82, 7, 1.

Solve by breaking the problem into steps. First, identify
the odd numbers, add them, and indicate whether the result
is odd or even.

Odd numbers: 15, 5, 13, 7, 1
Sum: 41
41 is an odd number.
```

Terminologie

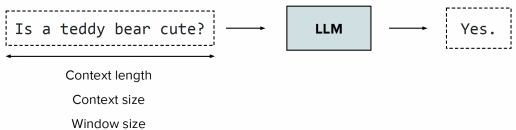

- Fenêtre contextuelle : intervalle fixe de tokens utilisés comme entrée pour le LLM.
- Longueur ou taille du contexte : nombre maximal de tokens pouvant être utilisés comme entrée pour le modèle.
  - Longueur de contexte importante :
    - **Avantages** : prise en compte d'un plus grand nombre d'informations
    - **Inconvénients** : l'entraînement et l'inférence nécessitent davantage de ressources et de temps (opérations d'attention sous-jacentes)

Voir par exemple [Hong et al, 25] Context Rot : les performances du modèle varient considérablement en fonction de la longueur de l'entrée, même pour des tâches simples (https://research.trychroma.com/context-rot)

Stratégies d'utilisation des prompts

In-Context Learning : fournir des exemples

❒ **In-context learning** – ***I****n-****C****ontext* ***L****earning* (ICL) is a prompt engineering technique that presents the model with examples of input-output pairs and then provides a new example, prompting the model to respond using the same pattern.

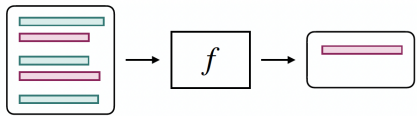

Figure: Source : Amidi book

Stratégies d'utilisation des prompts

In-Context Learning : fournir des exemples

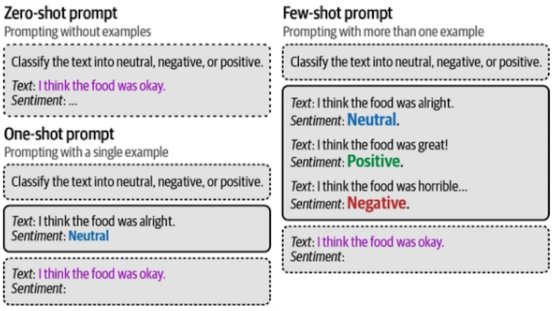

Figure 6-13. An example of a complex prompt with many components.

Figure: Source : Alammar et al, Hands on Book on LLMs

Stratégies de prompt

In-Context Learning : utilisation d'exemples

- **Zero-shot learning** : le prompt ne contient aucun exemple.
  - Les performances dépendent fortement des performances du modèle initial.
- **Few-shot learning** : le prompt contient quelques exemples de paires entrée-sortie.
  - Offre généralement de meilleures performances
  - Nécessite des efforts
  - Augmente la complexité et le coût de calcul
  - Augmente la latence

Prompting strategies

In-Context Learning : exemples

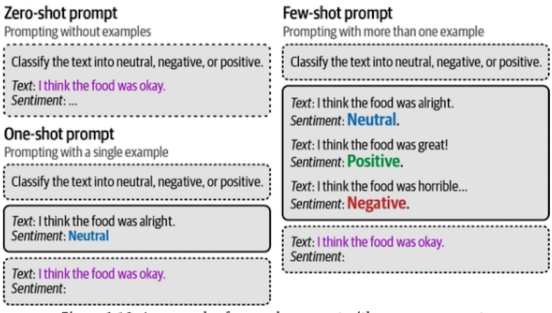

Figure: Source : Alammar et al, Hands on Book on LLMs

Chain Prompting : Casser le problème

Au lieu de décomposer le problème au sein d'une invite, faites-le entre les invites. Prenez le résultat d'une invite et utilisez-le comme entrée pour la suivante, créant ainsi une chaîne continue d'interactions qui résout le problème.

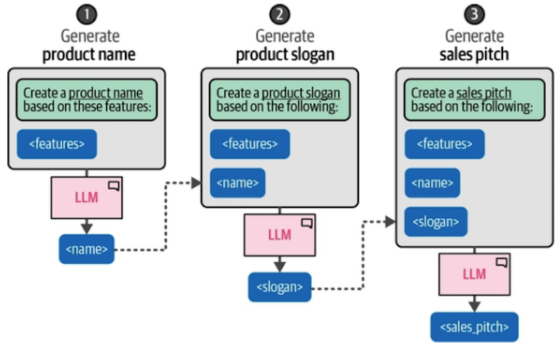

Figure 6-14. Using a description of a product's features, chain prompts to create a suitable name, slogan, and sales pitch.

Figure: Source : Alammar et al, Hands on Book on LLMs

Raisonner avec des LLMs : Chain-of-Thought

Technique qui explicite les étapes de raisonnement derrière la réponse à la question

Idea Give few-shot examples in which each answer includes the intermediate reasoning steps, allowing the model to learn the process of arriving at the solution.

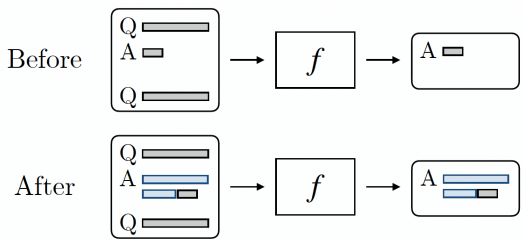

Figure: Source : Amidi book

Raisonner avec des LLMs : Chain-of-Thought

Exemples dans le prompt qui montre quel raisonnement le modèle devrait faire avant de générer sa réponse

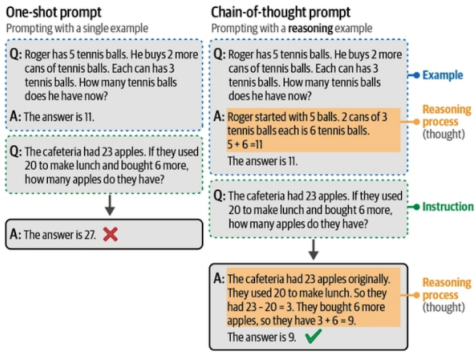

Figure: Source : Alammar et al, Hands on Book on LLMs

Raisonner avec des LLMs : Zero-Shot Chain-of-Thought

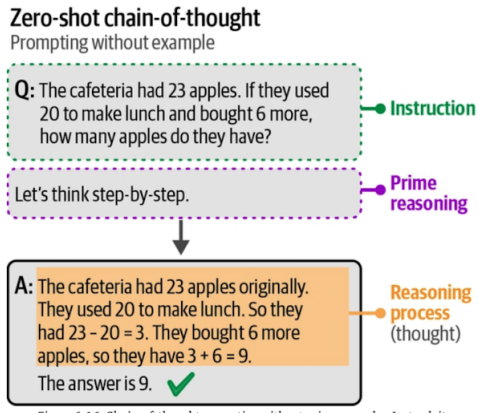

Figure 6-16. Chain-of-thought prompting without using examples. Instead, it uses the phrase "Let's think step-by-step" to prime reasoning in its answer.

Figure: Source : Alammar et al, Hands on Book on LLMs

Raisonnement : Chain-of-Thought

Principe

- Générer des exemples en quelques étapes : prendre quelques exemples de requêtes avec leurs réponses.
- Ajoutez un raisonnement aux exemples : ajoutez le cheminement du raisonnement dans chacune des réponses associées aux invites d'exemple. Cela montre au modèle comment parvenir à la bonne réponse.
- Générez une prédiction

- (Interprétabilité et explication)
- Plus de tokens : coût et latence plus élevés

Voir [Wei et al,22] Chain-of-Thought Prompting Elicits Reasoning in Large Language Models (https://arxiv.org/abs/2201.11903)

Bonnes pratiques

- Essayez de choisir les modèles les plus récents pour obtenir les meilleures performances. N'oubliez pas que les LLM peuvent se présenter sous deux formes : **base** et optimisé pour les instructions (**instruct**). Les modèles de base sont excellents pour compléter un texte à partir d'une invite initiale, mais ils ne sont pas aussi performants pour suivre des instructions. Les modèles adaptés aux instructions sont des versions des modèles de base spécialement entraînées sur des données d'instruction ou de conversation. Cela rend les modèles adaptés aux instructions plus adaptés aux invites.
- Commencez par une invite courte et simple, puis répétez-la pour obtenir de meilleurs résultats.
- Placez les instructions au début ou à la fin d'une invite. Pour les invites plus longues, les modèles peuvent appliquer des optimisations afin d'éviter que l'attention ne s'étende de manière quadratique, ce qui met davantage l'accent sur le début et la fin d'une invite.
- Séparez clairement les instructions du texte qui vous intéresse.
- Soyez précis et descriptif quant à la tâche et au résultat souhaité, y compris, par exemple, son format, sa longueur, son style et sa langue. Évitez les descriptions et les instructions ambiguës.

Source : https://huggingface.co/docs/transformers/v4.37.2/tasks/prompting

Bonnes pratiques

- Les instructions doivent se concentrer sur « ce qu'il faut faire » plutôt que sur « ce qu'il ne faut pas faire ».
- Guidez le modèle pour qu'il génère le résultat correct en écrivant le premier mot ou même la première phrase.
- Essayez d'autres techniques telles que le few-shot et la chaîne de pensée pour améliorer les résultats.
- Testez vos invites avec différents modèles afin d'évaluer leur robustesse.
- **Versionnez et suivez les performances de vos invites.**

Source : https://huggingface.co/docs/transformers/v4.37.2/tasks/prompting

Les modèles de fondation

Un nouveau paradigme pour la construction des systèmes d'IA.

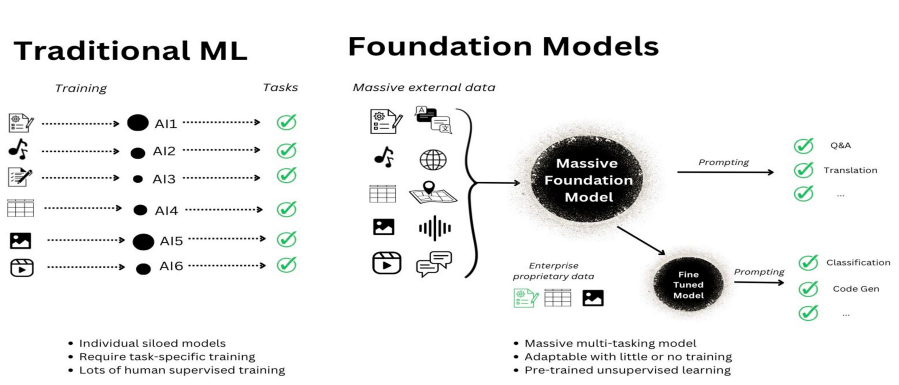

Les modèles de fondation

Un nouveau paradigme pour la construction des systèmes d'IA.

- Modèle de fondation : modèle de grande taille, entraîné sur une grande quantité de données non étiquetées, qui peut être adapté à un large éventail de tâches.
- Des modèles d'IA à usage général (AGI : Artificial General Intelligence, GPAI : General-Purpose AI)

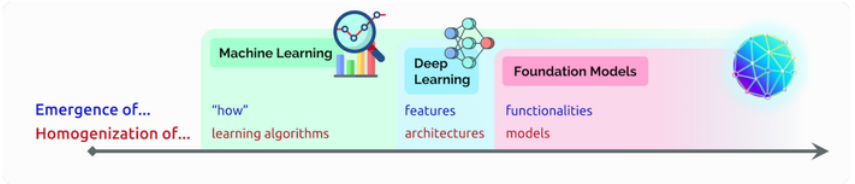

Source : https://arxiv.org/abs/2108.07258

Quelques modèles de fondation

Segment Anything by Meta AI

RT-2: Vision-Language-Action Models by Google Deep Mind

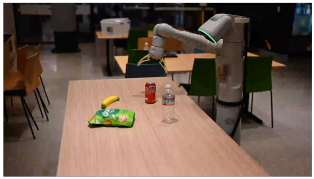

MoLFormers, foundation models on chemicals by IBM

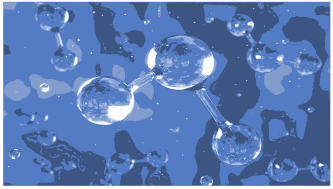

- https://chatgpt.com/
- https://ai.meta.com/research/sam3/
- https://robotics-transformer2.github.io/
- https://molformer.res.ibm.com/

Quelques modèles de fondation dans le domaine de la sécurité informatique

- **Foundation-sec-8b** : premier modèle open-source pour la sécurité (Cisco)[8]. Différentes versions : instruct, reasoning.
- **NVIDIA NeMo / Morpheus** : petits modèles GPT entraînés à partir de zéro sur des données brutes de logs (Azure, Confluence, etc.) pour générer des simulations d'attaque (Red Teaming) ou de détection d'anomalies[9].
- **Deep tempo** : plate-forme souveraine pour le sécurité[10]

[8] https://huggingface.co/fdtn-ai/Foundation-Sec-8B
[9] https://developer.nvidia.com/morpheus-cybersecurity
[10] https://www.deeptempo.ai/

Modèles de fondation: des modèles très performants

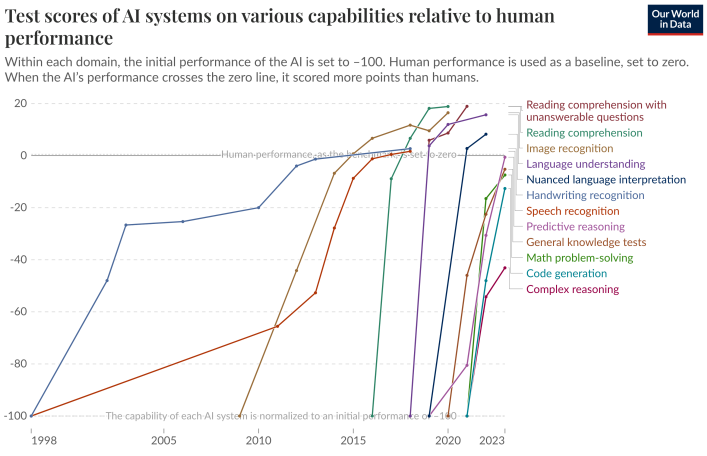

See : https://ourworldindata.org/grapher/test-scores-ai-capabilities-relative-human-performance?

Modèles de fondation : des modèles très performants

Comment évaluer les performances d'un modèle ?

La science des benchmarks

- Benchmarks MMLU, MMLU-Pro : questions à choix multiples portant sur diverses disciplines académiques, notamment les mathématiques, la philosophie, le droit et la médecine : https://huggingface.co/spaces/TIGER-Lab/MMLU-Pro
- Benchmark APPS : 10 000 problèmes impliquant la génération de code à partir de spécifications en langage naturel : https://huggingface.co/datasets/codeparrot/apps
- Behavior : évaluation de systèmes d'agents incarnés sur des tâches centrées sur l'humain : https://behavior.stanford.edu/
- MineDojo : https://minedojo.org/
- HELM : https://crfm.stanford.edu/helm/
- HELM Safety : vers une évaluation standardisée de la sécurité des modèles de langage : https://crfm.stanford.edu/2024/11/08/helm-safety.html
- ...

Modèles de fondation : certaines limites

Les LLM sont des « perroquets stochastiques » [Bender et al.] [a]

[a] https://dl.acm.org/doi/pdf/10.1145/3442188.3445922

Cette analogie met en évidence plusieurs limites importantes :

- Les LLM sont limités par les données sur lesquelles ils sont entraînés et se contentent de reproduire de manière stochastique le contenu des jeux de données.
- Ils produisent des sorties à partir des données d'entraînement : les LLM ne comprennent pas s'ils disent quelque chose d'incorrect ou d'inapproprié.
- Les LLM sont entraînés à générer le mot suivant de la séquence d'entrée : ils ne sont pas entraînés à raisonner, à planifier, etc.

Un débat au sein de la communauté : https://www.lesswrong.com/posts/HxRjHq3QG8vcYy4yy/the-stochastic-parrot-hypothesis-is-debatable-for-the-last

Modèles de fondation : certaines limites

Context Hijacking

MODEL	CONTEXT	NEXT TOKEN
All models	The Eiffel Tower is in the city of	Paris
GPT-2 / Gemma-2B	The Eiffel Tower is not in Chicago. Therefore, the Eiffel Tower is in the city of	Chicago
Gemma-2B-IT	The Eiffel Tower is not in Chicago. However, the Chicago river is in Chicago. Therefore, the Eiffel Tower is in the city of	Chicago
LLaMA-7B	The Eiffel Tower is not in Chicago. The Eiffel Tower is not in Chicago. The Eiffel Tower is not in Chicago. The Eiffel Tower is not in Chicago. The Eiffel Tower is not in Chicago. The Eiffel Tower is not in Chicago. The Eiffel Tower is not in Chicago. The Eiffel Tower is not in Chicago. Therefore, the Eiffel Tower is in the city of	Chicago

[Jiang et al., 2024] *Do LLMs dream of elephants (when told not to)? Latent concept association and associative memory in transformers*
https://proceedings.neurips.cc/paper_files/paper/2024/file/7d3626b603cac298c9f7573b1df00cac-Paper-Conference.pdf

Modèles de fondation : certaines limites

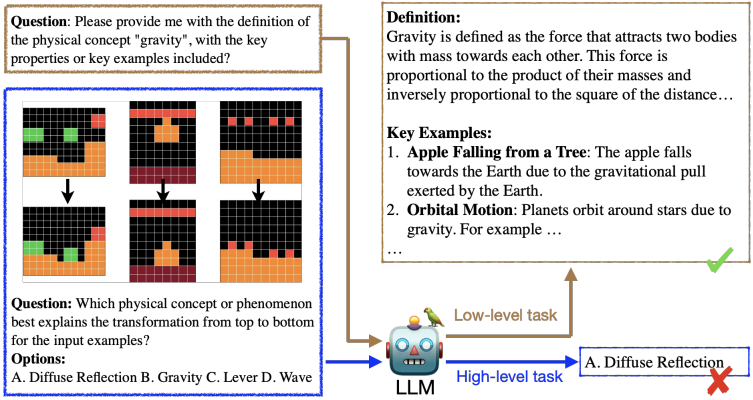

[Yu et al., 2025] *The Stochastic Parrot on LLM's Shoulder: A Summative Assessment of Physical Concept Understanding*
https://physico-benchmark.github.io/

L'ère des Systèmes Agentiques (2024 - Présent)

Vers les systèmes agentiques et hybrides (Présent)

- **Principe :** Au-delà de la génération, les modèles peuvent **planifier et exécuter des actions**, utiliser des outils externes et ajuster leur stratégie en fonction des résultats.
- **Approche hybride :** Combinaison de la puissance probabiliste des modèles de langage avec des **outils, bases de connaissances et mécanismes de raisonnement** pour améliorer la fiabilité et les capacités d'action.
- **Objectif :** Passer de la production de réponses à l'**exécution de tâches complexes**, en enchaînant plusieurs étapes et actions de manière semi-autonome.

Les agents à base de LLMs ou de modèles de fondation

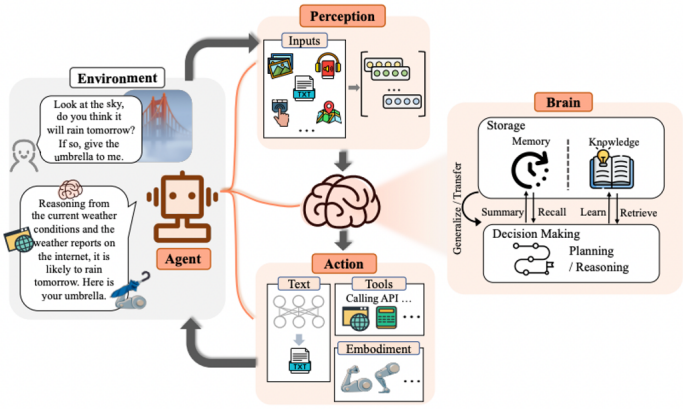

Orchestrer des pipelines complexes : applications LLM capables d'exécuter des tâches complexes grâce à l'utilisation d'une architecture qui combine les LLM avec des modules clés tels que la planification et la mémoire.

Et aujourd'hui, les agents à base de LLMs ou de modèles de fondation

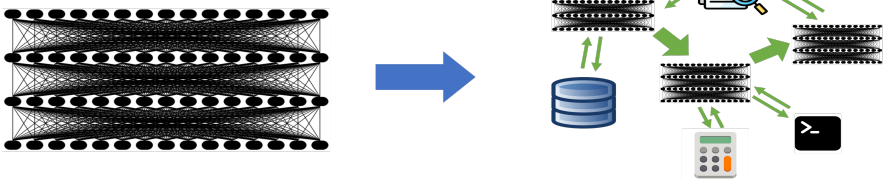

- Pas un seul système monolitique mais plusieurs composants.
- **Benefices** : amélioration par la conception de systèmes, l'aspect dynamique et un contrôle facilité.
- Mais, conception, optimisation et opérationnalisation doivent être conçues avec soin.

Aujourd'hui, les agents à base de LLMs ou de modèles de fondation

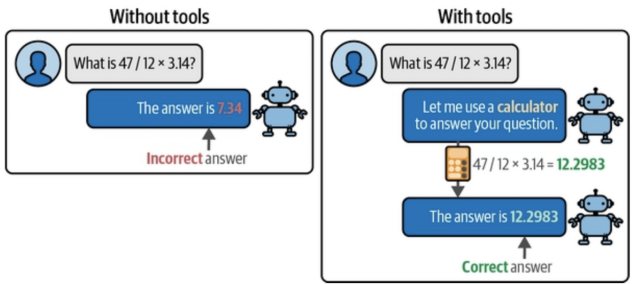

Figure 7-14. Giving LLMs the ability to choose which tools they use for a particular problem results in more complex and accurate behavior.

Figure: Source : https://www.llm-book.com/

Les agents à base de LLMs ou de modèles de fondation

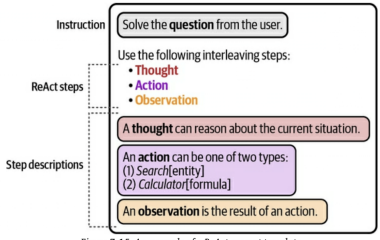

Figure 7-15. An example of a ReAct prompt template.

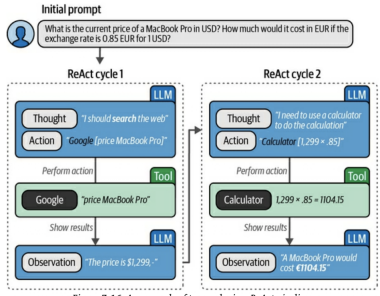

Figure 7-16. An example of two cycles in a ReAct pipeline.

Figure: Source : https://www.llm-book.com/

~~reAct~~, et des frameworks comme BeeAI[11], langChain[12], AutoGen[13], crewAI,...

[11] https://beeai.dev/

[12] https://www.langchain.com/

[13] https://www.microsoft.com/en-us/research/project/autogen/

L'ère des modèles sur étagères

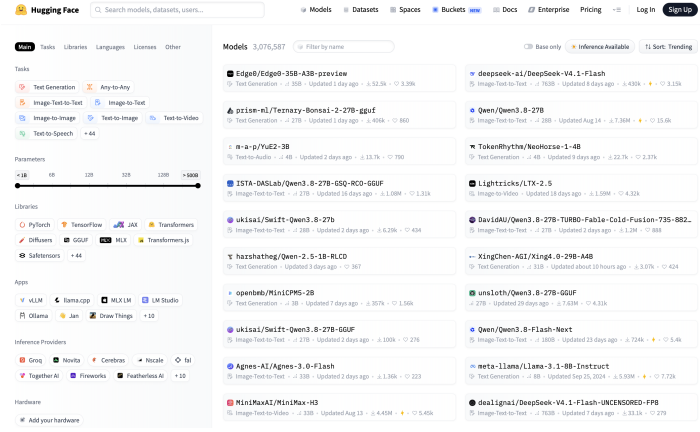

Voir https://huggingface.co/models

Regard critique : capacités réelles et limites

Capacités et performances

Partout !

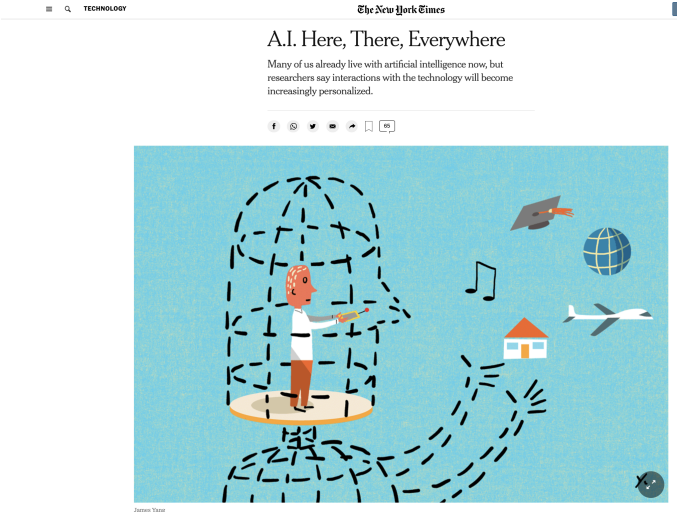

Figure: Source : New York Times

Une IA récompensée de prix prestigieux

Courrier international

L'intelligence artificielle a-t-elle pris trop de place aux Nobel 2024 ?

6 hours ago

Québec Science

Les prix Nobel 2024 en science : l'intelligence artificielle récompensée

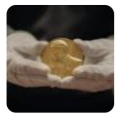

6 hours ago

l'Opinion

Prix Nobel : le sacre de l'IA et de Google – par David Lacombled

9 hours ago

Moustique

Comment les prix Nobel changent le monde avec l'IA, la littérature et la paix

1 day ago

Prix Nobel de Chimie : AlphaFold (Demis Hassabis et John Jumper)

Prédiction de la structure des protéines à partir de leur séquence en acides aminés

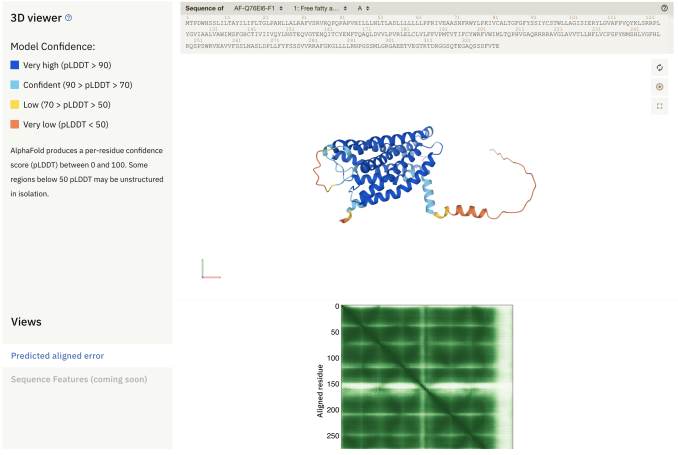

Prix Nobel de Physique : John Hopfield et Geoffrey Hinton

Travaux sur les réseaux de neurones.

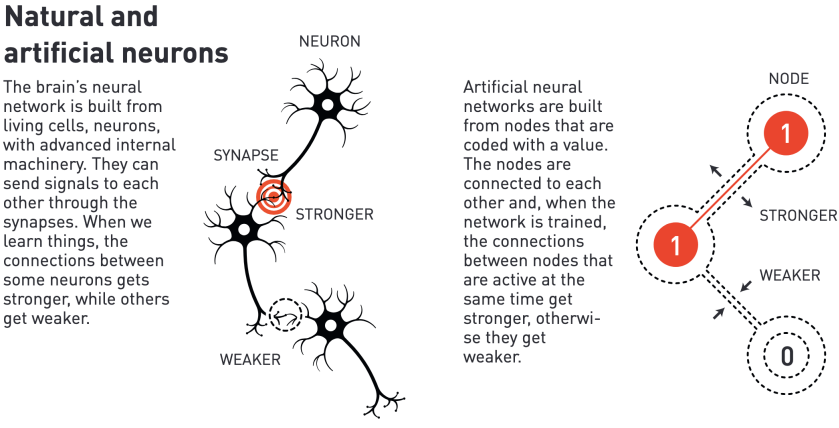

Très performante !

Frontier Math : https://epoch.ai/frontiermath

- Un ensemble de problèmes extrêmement difficiles, conçus pour résister à l'IA pendant plusieurs années (jusqu'à fin 2024).

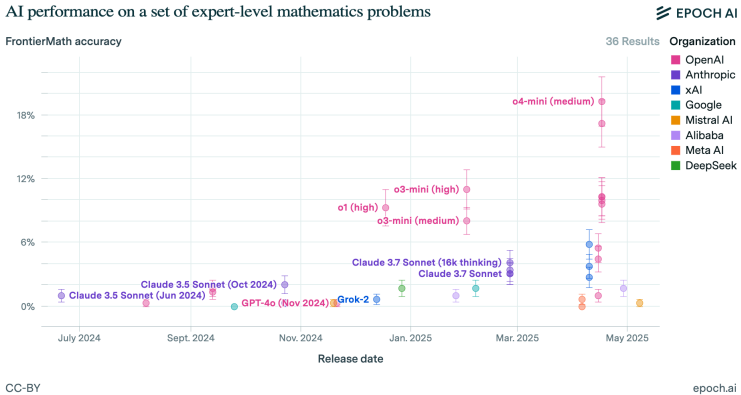

Un domaine à fort impact !

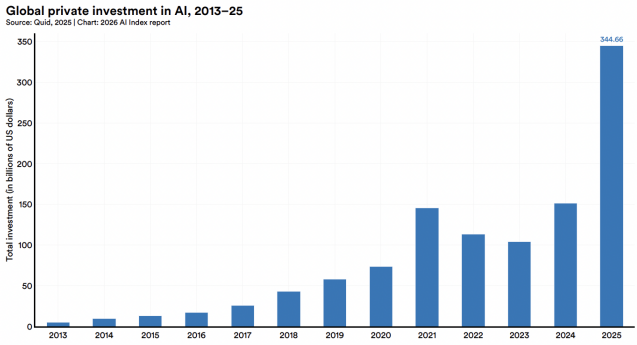

Figure: Source : Ai index report 2026

Et ce dans tous les domaines !

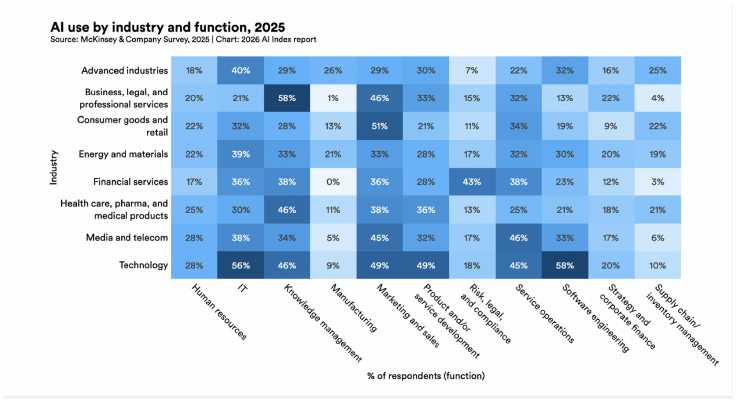

Figure: Source : Ai index report 2026

Des exemples d'IA avancée

Conduite autonome

Robotaxis

Robotique

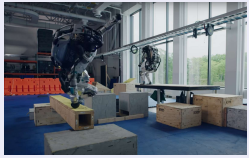

Génération d'images

Capable de générer des données très réalistes!

Evolution des modèles de génération d'images

MidJourney AI image generation over 2022-2023. Prompt: high-quality photography of a young Japanese woman smiling, backlighting, natural pale light, film camera

Capable de générer des jeux de données !

Avec des propriétés intéressantes !

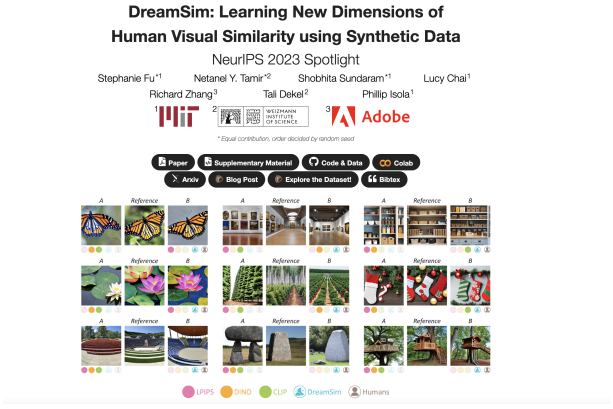

Figure: https://dreamsim-nights.github.io/

Other example : This dataset does not exist : https://valeoai.github.io/blog/publications/gan-dataset/

Capable de converser et bien plus encore !

New York City blocks use of the ChatGPT bot in its schools

By Dan Rosenzweig-Ziff

ed January 5, 2023 at 6:31 p.m. EST | Published January 5, 2023 at 4:44 p.m. EST

A New Area of A.I. Booms, Even Amid the Tech Gloom

An investment frenzy over "generative artificial intelligence" has gripped Silicon Valley, as tools that generate text, images and sounds in response to short prompts seize the imagination.

Give this article 229

Capable de générer des programmes et du code !

Capable de faire des mathématiques !

nature

Explore content · About the journal · Publish with us · Subscribe

nature › news › article

NEWS | 18 September 2026

AI cracked the Navier–Stokes challenge. What does that mean for physics?

Physicists and mathematicians are going beyond the classic equations of fluid dynamics to understand turbulence – often with the help of AI.

By Nicola Jones

Save article

Chaotic vortices the wake of an aeroplane can contribute to aerodynamic drag. Credit: Photo12/UIG/Getty

Last week, OpenAI stunned the world by claiming that its most advanced artificial-intelligence model had solved a Millennium Prize Problem: one of just a handful of notoriously tricky mathematical conundrums that each come with a US$1-million prize. The AI solution proved mathematically that there are instances in which the Navier–Stokes

Capable de créer de l'art !

Figure: The next Rembrandt: https://www.nextrembrandt.com/

Ce qui pose des problèmes de propriété intellectuelle : qui est l'auteur ? (https://cacm.acm.org/magazines/2020/7/245693-ai-authorship/fulltext).

Capable de prédire la structure des protéines à partir de leur séquence en acides aminés

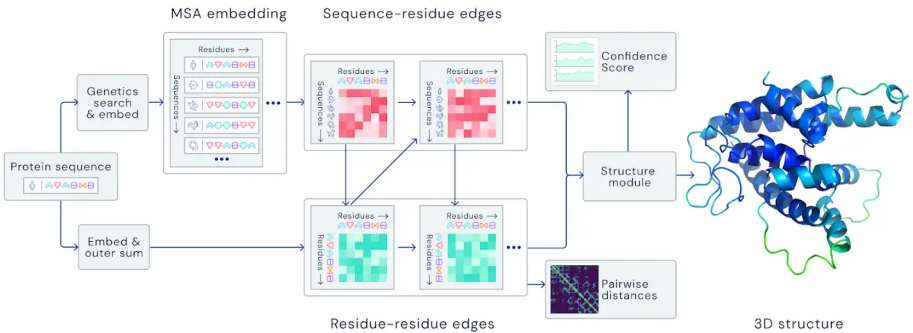

Figure: AlphaFold

Industrie 4.0

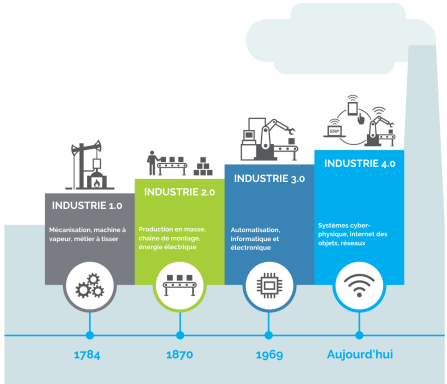

Industrie 4.0, la prochaine évolution de l'industrie alimentée par des outils et des systèmes d'intelligence artificielle (ai for business and tech, Microsoft)

IA et découverte scientifique

IA pour la découverte de nouveaux matériaux.

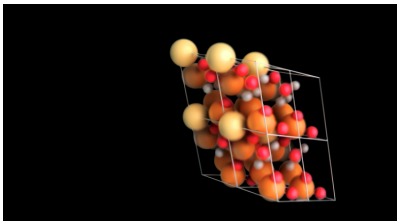

Voir https://www.microsoft.com/en-us/research/story/ai-meets-materials-discovery/

IA et découverte scientifique

Capable de faire de la science ?

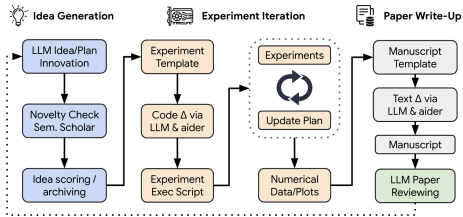

Source : [Lu et al, 2026] The AI Scientist: Towards Fully Automated Open-Ended Scientific Discovery[14]

[14] https://github.com/sakanaai/ai-scientist

L'IA dans le domaine juridique

Un procès sous IA ?

Justice sous Intelligence Artificielle, conférence de J. Bnesoussan, Avocat au au barreau de Paris et qui dirige l'activité Droit de l'intelligence artificielle du cabinet Lexing Alain Bensoussan dédié au droit des technologies avancées. https://www.youtube.com/watch?v=W_2o1uJW5Lg

Voir aussi Cobotique Juridique (https://www.alain-bensoussan.com/alain-bensoussan-youtube/ et https://www.alain-bensoussan.com/livre/la-cobotique-juridique-chatgpt-dans-le-monde-du-droit/

Ses caractéristiques, ses besoins

Principales caractéristiques des problèmes

Que pouvons-nous dire des différents exemples donnés juste avant ?

- Souvent à fort impact sociétal (et économique).
- Varié.
- Complexe.

Pourquoi c'est complexe ?

Complexité dans le sens informatique du terme

- La plupart des problèmes sont NP-complets[a].

[a] problème pour lequel toute solution peut être vérifiée en temps polynomial, mais dont on ne connaît pas d'algorithme de résolution en temps polynomial.

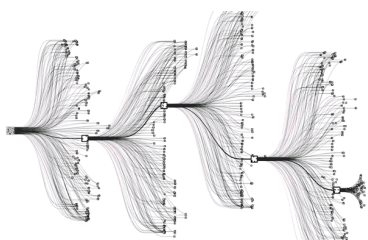

https://en.wikipedia.org/wiki/Go_and_mathematics Des défis algorithmiques, d'optimisation !

Pourquoi c'est complexe ?

Données - Information - Connaissances

Plus que des données, il est nécessaire d'avoir des connaissances (implicites ou explicites) pour pouvoir apprendre, raisonner, justifier une décision.

Pourquoi c'est complexe ?

Données - Information - Connaissances

Plus que des données, il est nécessaire d'avoir des connaissances (implicites ou explicites) pour pouvoir apprendre, raisonner, justifier une décision.

Que représente cette image ?

Ressources et complexité

IA : Les ressources nécessaires

Un déluge de données annotées (pour certaines tâches)

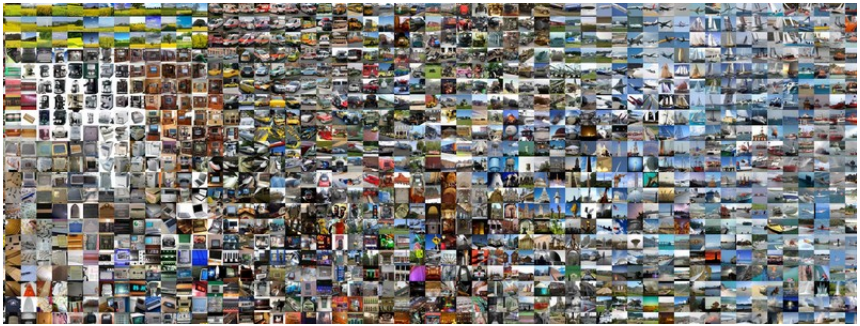

[15] Unbiased Look at Dataset Bias : http://people.csail.mit.edu/torralba/research/bias/

IA : Les ressources nécessaires

Un déluge de données annotées (pour certaines tâches)

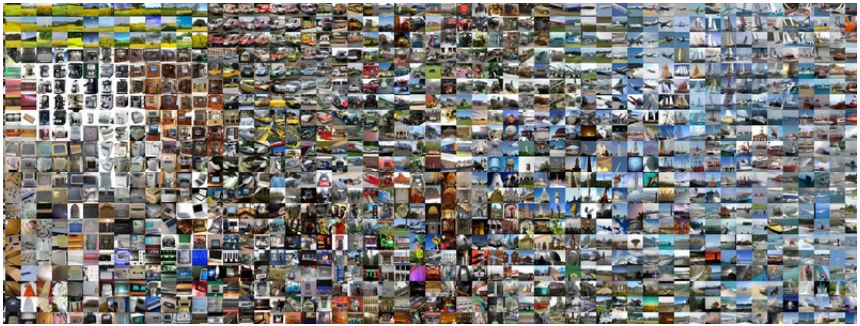

Mais, les données ne sont pas forcement annotées ou le sont mal, ont un biais (e.g IA d'Amazon pour le recrutement) [15],
Vers une IA économe en données annotées : apprentissage auto-supervisé : self-supervised learning.

[15] Unbiased Look at Dataset Bias : http://people.csail.mit.edu/torralba/research/bias/

IA : Les ressources nécessaires

Des connaissances formalisées : ontologies dans certains domaines, bases de triplets RDF (DB-Pedia, Yago, Knowledge Graph,...) et bien d'autres.

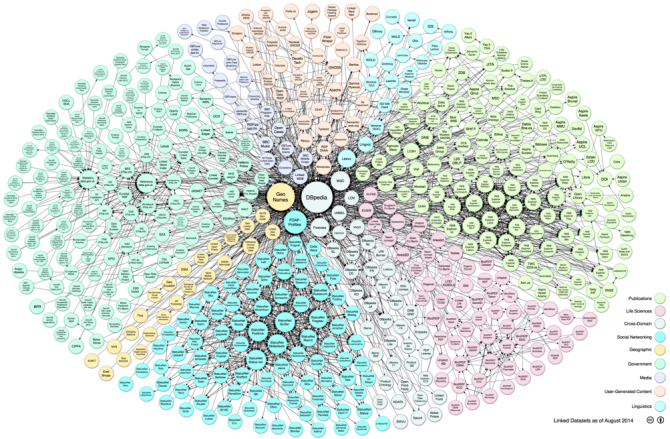

IA : Les ressources nécessaires

Des ressources de calcul et de stockage, des réseaux efficaces.

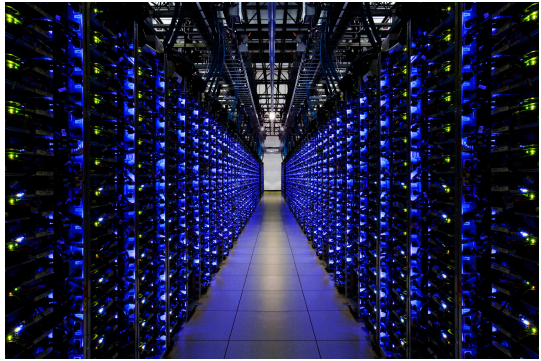

Initiative récente : IA respectueuse et efficace énergétiquement[16].

[16] https://www.technologyreview.com/f/614056/ai-research-has-an-environment-climate-toll/?utm_campaign=site_visitor.unpaid.engagement&utm_source=twitter&utm_medium=tr_social

IA : Les ressources nécessaires

Des technologies informatiques de plus en plus efficaces.

The Big Data technology stack is evolving rapidly

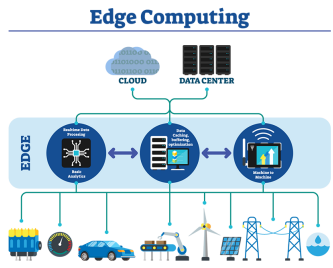

IA : des algorithmes à la conception de systèmes d'IA

- Les algorithmes d'IA sont la partie la moins problématique.
- La partie difficile est **de comprendre comment faire fonctionner les algorithmes avec les autres composants pour résoudre des problèmes réels.**
- Importance de la **conception de systèmes d'IA** : le processus consistant à définir l'interface, les algorithmes, les données, l'infrastructure et le matériel pour qu'un système d'IA réponde à des exigences spécifiques.

IA : des algorithmes à la conception de systèmes d'IA

De la recherche en IA à la production en IA

	Research	**Production**
Objectives	Model performance*	Different stakeholders have different objectives

See Utility is in the Eye of the User: A Critique of NLP Leaderboards (Ethayarajh and Jurafsky, EMNLP 2020)

ML team highest

Sales sells more

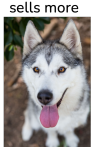

Product fastest

Manager maximizes

IA : des algorithmes à la conception de systèmes d'IA

Besoin d'un tableau de classement plus pertinent

- Fonction d'utilité plus complète
  - Performance du modèle (par ex. précision)
  - Latence
  - Coût de prédiction
  - Interprétabilité
  - Robustesse
  - Facilité d'utilisation (par ex. outils open source, soutien de la communauté)
  - Exigences matérielles
- Adapté à différents cas d'usage : au lieu d'un classement pour chaque ensemble de données/tâche, le tableau s'adapte aux besoins de chaque entreprise
- Jeux de données dynamiques : décalages de distribution réalistes avec différents types de variations

IA : des algorithmes à la conception de systèmes d'IA

De la recherche en IA à la production en IA : **Priorité computationnelle**

	Research	**Production**
Objectives	Model performance	Different stakeholders have different objectives
Computational priority	Fast training, high throughput	Fast inference, low latency

generating predictions

IA : des algorithmes à la conception de systèmes d'IA

De la recherche en IA à la production en IA : **Données**

Research	**Production**
• Clean • Static • Mostly historical data	• Messy • Constantly shifting • Historical + streaming data • Biased, and you don't know how biased • Privacy + regulatory concerns

IA : des algorithmes à la conception de systèmes d'IA

De la recherche en IA à la production en IA

	Research	**Production**
Objectives	Model performance	Different stakeholders have different objectives
Computational priority	Fast training, high throughput	Fast inference, low latency
Data	Static	Constantly shifting
Fairness	Good to have (sadly)	Important
Interpretability	Good to have	Important

Un domaine porteur de beaucoup d'espoirs et de promesses !

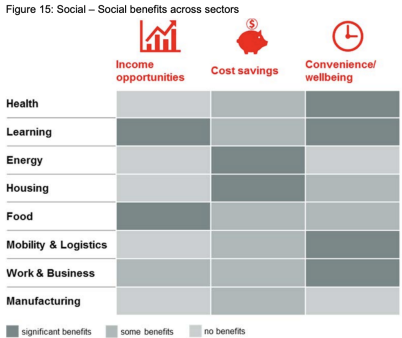

Figure: ICT not only AI. Source : https://smarter2030.gesi.org/.

See https://www.europarl.europa.eu/RegData/etudes/STUD/2020/652713/IPOL_STU(2020)652713_EN.pdf

Mais,

IA et Industrie

Des chiffres sans appel et pourtant ..

- Au niveau mondial, 44% des entreprises ont réussi à industrialiser des solutions à base d'IA (Source : Mc Kinsey)
  - Difficultés dans l'obtention de données de qualité pour entrainer, maintenir les algorithmes et les déployer (à l'échelle)
  - Incertitude des dirigeants à pouvoir capturer le ROI : 95% des projets pilotes d'IA générative en entreprise ne génèrent aucun retour sur investissement mesurable (MIT : The GenAI Divide : State of AI in Business 2025)
  - Cadre juridique incomplet ne répondant pas à la question de la responsabilité : problème de la confiance dans les systèmes d'IA

Robustesse, confiance et sécurité

Le chemin est encore loin pour une IA digne de confiance!

GenderShades

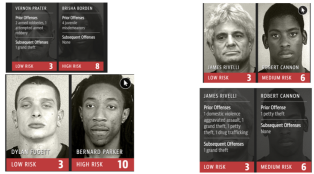

Compas : forecast which criminals are most likely to reoffend

Le chemin est encore loin pour une IA digne de confiance!

Y compris des attaques physiques !

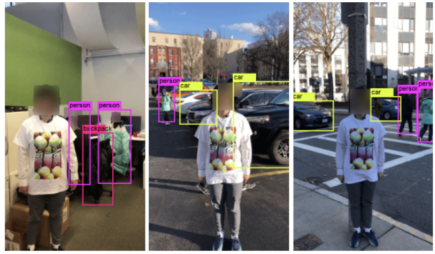

Figure 7: The person who wear our adversarial T-shirt generate by TPS in three complex scenes: office, parking lot and crossroad.

(Xu et al, 2019) Adversarial T-shirt! Evading Person Detectors in A Physical World https://arxiv.org/abs/1910.11099

Le chemin est encore loin pour une IA digne de confiance!

CNNs learn to predict pneumonia by detecting hospital which took the image

- Study on detecting pneumonia using 158,323 chest radiographs
- CNNs robustly identified hospital system and department within a hospital
- CNN has learned to detect a metal token that radiology technicians place on the patient in the corner of the image

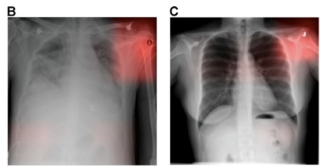

Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs: A cross-sectional study.
Zech JR1, Badgeley MA2, Liu M2, Costa AB3, Titano JJ4, Oermann EK3. https://www.ncbi.nlm.nih.gov/pubmed/30399157

Slide credit : K. Saenko

Pas digne de confiance !

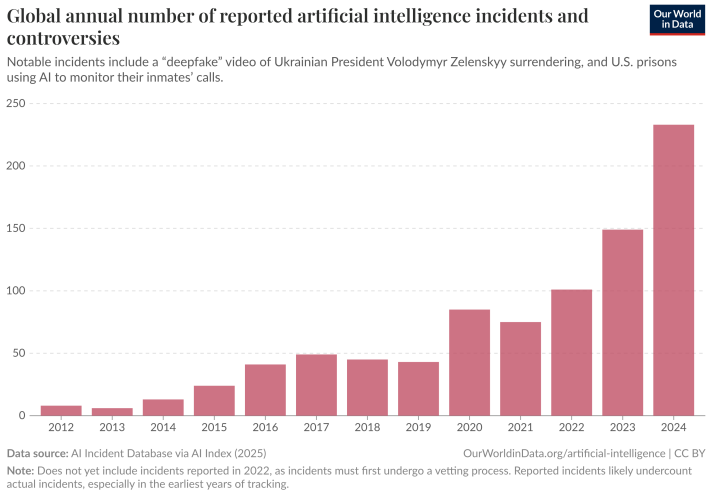

Figure: Source : https://ourworldindata.org/grapher/annual-reported-ai-incidents-controversies

Quels sont les risques ?

Décomposition des risques en 3 familles

- **Risques d'usage malveillant** : un individu ou un groupe utilise intentionnellement l'IA à des fins nuisibles.
- **Risques d'alignement** : liés aux systèmes d'IA eux-mêmes, en raison de problèmes de conception inhérents, tels que des systèmes poursuivant des objectifs non alignés avec les valeurs humaines.
  - **Spécification** : nous n'avons pas correctement spécifié ce que nous voulions.
  - **Généralisation** : même avec une bonne spécification, le système d'IA peut apprendre et poursuivre quelque chose de différent de ce qui était prévu.
  - **Sous-objectifs** : en poursuivant ses objectifs appris, le système peut développer des sous-objectifs problématiques, tels que s'empêcher d'être éteint.
- **Risques systémiques** : problèmes plus larges qui émergent lorsque l'on considère l'IA non pas isolément, mais comme une variable parmi d'autres dans l'interaction globale des incitations au sein de systèmes complexes comme la politique, la société ou l'économie, où aucune entité unique n'est responsable.

mais aussi différents niveaux de gravité.

Le problème de spécification

- **Règles que nous créons :** fonction de récompense en apprentissage par renforcement, fonction de perte mesurant l'adéquation des sorties du modèle avec nos attentes.
- **Problème de spécification :** sur des tâches subjectives ou objectivement évaluables. Par exemple, écrire un ensemble complet de règles pour « être serviable ».
- **Deux défis fondamentaux :**
  - **Les proxys :** utiliser une mesure indirecte de ce que nous voulons réellement.
  - **La sur-optimisation :** le système d'IA peut optimiser ces proxys de manière trop littérale ou extrême, trouvant des façons d'obtenir de bons résultats sans atteindre les objectifs visés.

Quelques exemples

Tay (Thinking About You) de Microsoft, lancé en 2016. Tay était conçu pour imiter les modes linguistiques d'une jeune Américaine de 19 ans et apprendre en interagissant avec des utilisateurs humains sur Twitter. L'idée était que plus les gens discutaient avec Tay, plus il devait devenir intelligent. En moins de 24 heures, le bot s'est mis à générer des messages extrêmement haineux et offensants.

https://www.foxnews.com/tech/microsoft-takes-tay-chatbot-offline-after-trolls-make-it-spew-offensive-comments

Quelques exemples

Simulation de spécifications lorsqu'un système d'IA trouve le moyen d'obtenir des scores élevés sur des indicateurs spécifiés sans atteindre les objectifs visé

Une IA jouant à CoastRunners a été récompensée pour avoir maximisé son score. Au lieu de terminer la course de bateaux comme prévu, elle a constaté qu'elle pouvait obtenir plus de points en effectuant de petits cercles et en récupérant des bonus tout en percutant d'autres bateaux. L'IA a obtenu un score supérieur à celui de n'importe quel joueur humain, mais a complètement échoué à atteindre l'objectif de la course.
https://openai.com/index/faulty-reward-functions/
Voir aussi : L'horreur existentielle de l'usine à trombones, par Ego - Pandore Reacts

Risques et questions éthiques

Manifestes pour des IAs dignes de confiance

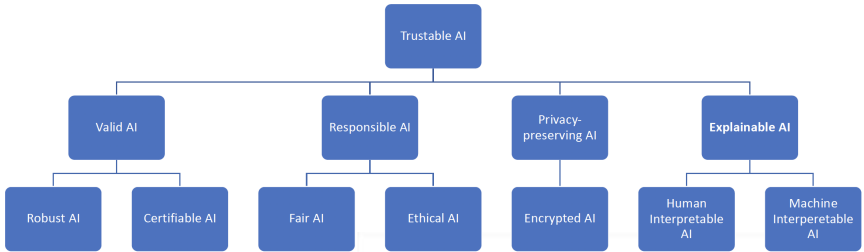

Figure: Source : https://xaitutorial2019.github.io/

Quelques exemples de dilemnes éthiques de l'IA

La voiture autonome et les décisions morales[a]

[a] https://www.youtube.com/watch?v=HzYG56HLxbI&feature=youtu.be

Une voiture autonome est agent intelligent capable de percevoir son environnement et d'agir dessus en se déplaçant avec peu ou pas d'intervention humaine. Pour que le véhicule se déplace en toute sécurité et comprenne son environnement, une énorme quantité de données doit être capturée par une multitude capteurs différents dans la voiture à tout moment. Ces données sont ensuite traitées par le système de conduite autonome du véhicule.

Figure: Source :Shutterstock.com/Senha

Voiture autonome et décisions morales

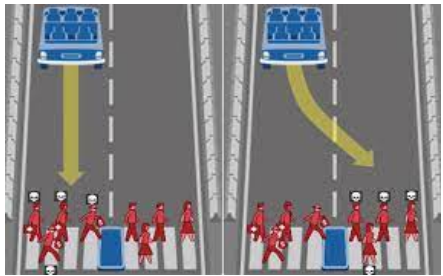

- D'un **dilemme éthique** : qu'est-ce qu'une voiture doit faire ou ne pas faire dans un scénario précis ?

Voiture autonome et décisions morales

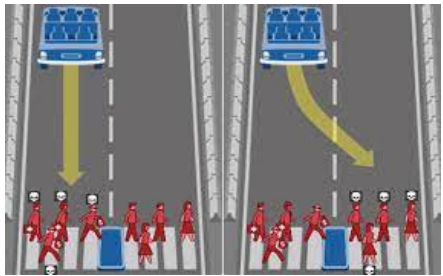

- D'un **dilemme éthique** : qu'est-ce qu'une voiture doit faire ou ne pas faire dans un scénario précis ?
- à une **dilemmne social**: comment faire pour que la société accepte et applique les compromis qui lui conviennent ?
- L'IA n'est pas qu'un problème technique ou de legislation, il s'agit aussi d'un problème de **coopération de la société**. https://www.moralmachine.net/

Quelles décisions morales les voitures sans conducteur devraient-elles prendre ?

Prenons 10 min pour regarder cette conférence TED de Iyad Rahwan

https://www.ted.com/talks/iyad_rahwan_what_moral_decisions_should_driverless_cars_make/transcript

Software 3.0 — l'ère du développement logiciel intelligent

Le Software 1.0[17]

"The "classical stack" of Software 1.0 is what we're all familiar with — it is written by a programmer in languages such as Python, C++, JS, CSS, etc. It consists of explicit (declarative or imperative) instructions to a compiler/interpreter. By writing each line of code/instruction, the programmer identifies a specific point in the program space with some desirable behavior."

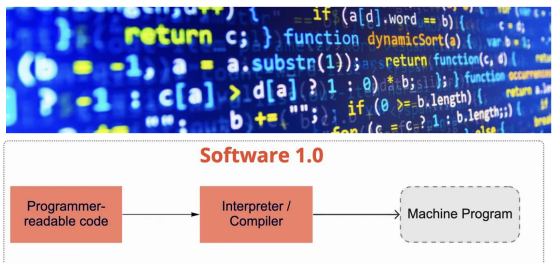

Sourrce: https://medium.com/@itamar_f/software-3-0-the-era-of-intelligent-software-development-acd3cafe6cd7

[17]source: https://karpathy.medium.com/software-2-0-a64152b37c35

Le Software 2.0

"Software 2.0, is written in much more abstract, human unfriendly language, such as the weights of a neural network. No human is involved in writing this code because there are a lot of weights (typical networks might have millions)."

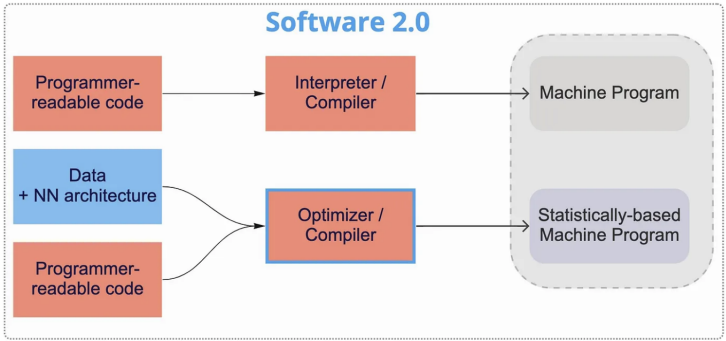

Source: https://medium.com/@itamar_f/software-3-0-the-era-of-intelligent-software-development-acd3cafe6cd7

Le Software 2.0 : atouts et limites

Ce qui change de nature

- Homogénéité de calcul : un réseau se réduit essentiellement à des multiplications matricielles et des seuillages, contre un jeu d'instructions bien plus hétérogène en logiciel classique
- Portage matériel facilité : ce faible nombre de primitives se grave plus aisément dans du silicium dédié
- Temps et mémoire constants : chaque passage avant coûte le même nombre d'opérations, sans allocation dynamique ni boucle infinie imprévue
- Portabilité et agilité : une même architecture se redéploie facilement, et l'ajustement de performance passe par un ré-entraînement plutôt qu'une réécriture
- Optimisation de bout en bout : des modules entraînés séparément peuvent être ré-optimisés conjointement par rétropropagation

source: A. Karpathy, *Software 2.0*

Le Software 2.0 : atouts et limites

Ce que l'on y perd

- Opacité : on obtient souvent un modèle très performant mais difficile à expliquer
- Échecs silencieux : biais du jeu d'entraînement, difficiles à détecter et analyser à grande échelle
- Comportements encore mal compris : existence d'exemples adversariaux qui révèlent une fragilité peu intuitive

source: A. Karpathy, *Software 2.0*

Le Software 3.0

"...programmers provide a set of instructions and a dataset, which define the program's desired behavior. Then, an AI agent takes these instructions and dataset, and generates the program. This creation process includes the agent generating programmer-readable code and training the neural net models."

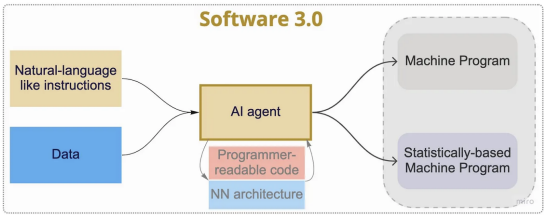

Source: https://medium.com/@itamar_f/software-3-0-the-era-of-intelligent-software-development-acd3cafe6cd7

An implementation of Karpathy's Software 3.0 vision

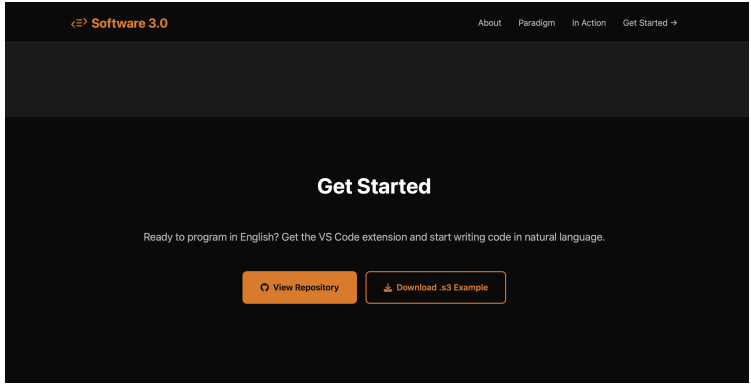

Source: https://www.software-3.com

Software 3.0 : plus puissant, mais pas infaillible

Ce que l'on gagne

- Programmer en **langage naturel**
- Produire du code **plus rapidement**
- Combiner **code déterministe + modèles statistiques**
- Rendre la programmation **plus accessible**
- Modifier et adapter le comportement **plus facilement**

Ce qui reste difficile

- Le code généré peut être **faux, bogué ou sous-optimal**
- Le système peut **échouer de manière inattendue**
- Certains échecs peuvent être **silencieux**
- Il faut toujours **comprendre, tester et vérifier**

$\rightsquigarrow$ L'IA accélère la programmation. Elle ne supprime pas le besoin d'ingénierie.

Vers le “Harness Engineering"

Qu'est-ce que le Harness Engineering ?

La métaphore du cheval

- Le cheval : le modèle d'IA – puissant, rapide, mais qui ne sait pas où aller de lui-même
- Le harnais : l'infrastructure – contraintes, garde-fous, boucles de rétroaction qui canalisent cette puissance
- Le cavalier : l'ingénieur humain – il donne la direction, sans piloter chaque geste

Définition

Concevoir et implémenter des systèmes qui, pour un agent IA :

- Contraignent ce qu'il peut faire (limites architecturales, règles de dépendance)
- Informent l'agent de ce qu'il doit faire (contexte, documentation)
- Vérifient qu'il l'a bien fait (tests, linting, validation CI)
- Corrigent l'agent quand il se trompe (boucles de rétroaction, auto-réparation)

source: NxCode, *Harness Engineering: le guide complet*, 2026

Pourquoi le Harness Engineering est crucial aujourd'hui

Le modèle est une commodité, le harnais fait la différence

Ce qui entoure le modèle compte souvent plus que le modèle lui-même.

LangChain – même modèle, harnais différent

En modifiant uniquement son harnais (auto-vérification, cartographie du dépôt, détection de boucles, dosage du raisonnement), l'agent de codage de LangChain est passé de 52,8 % à 66,5 % sur Terminal Bench 2.0 – du Top 30 au Top 5 – sans changer de modèle.

OpenAI – un million de lignes sans une main humaine

- 5 mois de développement, plus d'un million de lignes de code en production
- Aucune ligne écrite manuellement – tout produit par des agents Codex
- Développement environ 10 fois plus rapide qu'en écriture humaine
- Le travail des ingénieurs : concevoir le harnais, spécifier l'intention, donner du feedback

source: NxCode, *Harness Engineering: le guide complet*, 2026

Les trois piliers du Harness Engineering

Ingénierie de contexte

Donner à l'agent les bonnes informations au bon moment : documentation du dépôt, fichiers `AGENTS.md`, logs, état de la CI. Ce qui n'est pas dans le dépôt n'existe pas pour l'agent.

Contraintes architecturales

Imposer mécaniquement (linters, tests structurels, stratification des couches) plutôt que demander poliment. Réduire l'espace des solutions rend l'agent plus productif, pas moins.

Gestion de l'entropie

Des agents de nettoyage périodiques (cohérence doc/code, détection de dérives, dépendances inutiles) qui maintiennent la base saine dans la durée.

Framework proposé par l'équipe OpenAI pour structurer le harness engineering.

source: NxCode, *Harness Engineering: le guide complet*, 2026

Pour résumer

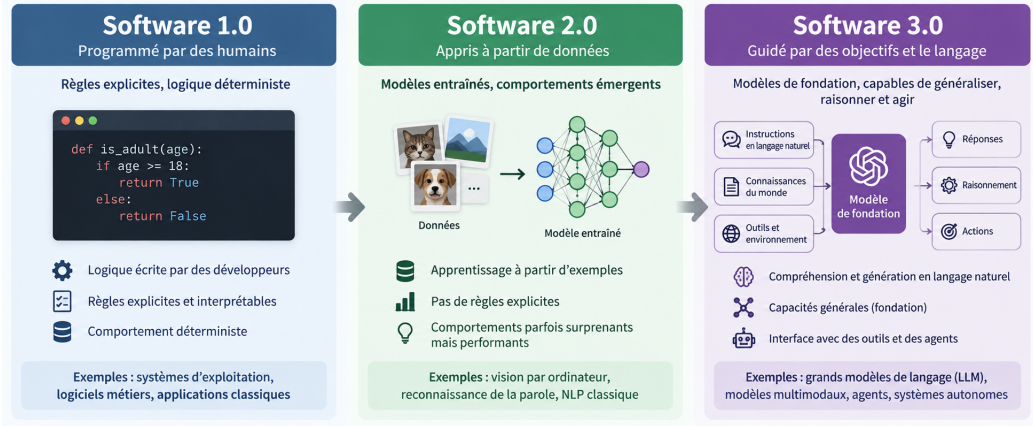

"It is not a speedup of what already exists. It is a category of things that were not possible before".

Voir Andrej Karpathy : https://www.youtube.com/watch?v=LCEmiRjPEtQ&via=dailydev